

Università degli Studi di Camerino

Scuola di Scienze e Tecnologie

Corso di Laurea in Fisica (Classe L-30)

Apprendimento automatico nella teoria del funzionale della densità

Laureando
Lorenzo Ducci

Matricola 123492

Relatore
Prof. Sebastiano Pilati

A.A. 2024/2025

Abstract

La teoria del funzionale della densità (DFT) rappresenta ad oggi uno dei metodi più diffusi per lo studio della struttura elettronica di molecole e solidi. Fondata sui teoremi di Hohenberg-Kohn, le proprietà fisiche di un sistema sono ricondotte al valore di un funzionale della densità elettronica dello stato fondamentale. Questo approccio permette in linea di principio di ridurre la complessità computazionale rispetto a metodi basati sulla funzione d'onda. Tuttavia, la forma esatta del funzionale non è nota a priori. In questa tesi si analizza la possibilità di utilizzare metodi per approssimare il funzionale sfruttando algoritmi di apprendimento automatico, con l'obiettivo di ricavare l'energia dello stato fondamentale con un'accuratezza maggiore rispetto alle tecniche di approssimazioni tradizionali.

Indice

1 Introduzione **7**

2 Teoria del funzionale della densità (DFT) **11**
2.1 Teoremi di Hohenberg-Kohn 12
2.2 Problema della V-rappresentabilità 13
2.3 Metodo di Kohn-Sham 14
2.3.1 Equazioni di Kohn-Sham 14
2.3.2 Soluzione delle equazioni di Kohn-Sham 15
2.3.3 Significato autovalori 17
2.3.4 Termine di scambio e correlazione 17
2.4 Orbital-Free DFT 18

3 Apprendimento automatico **21**
3.1 Paradigmi di apprendimento 21
3.1.1 Apprendimento non supervisionato 21
3.1.2 Apprendimento supervisionato 22
3.2 Processo di apprendimento 22
3.2.1 Algoritmo di discesa del gradiente 22
3.2.2 Problema di underfitting e overfitting 23
3.3 Reti neurali artificiali 25
3.3.1 Multilayer Perceptron (MLP) 25
3.3.2 Rete neurali convoluzionali 27
3.4 Autoencoder variazionali 28
3.4.1 Architettura 28
3.4.2 Addestramento 29
3.5 Applicazioni nella DFT 30

4 Rete neurale convoluzionale per il termine cinetico **33**
4.1 Dati di addestramento 33
4.1.1 Sistema di singolo elettrone 34
4.1.2 Sistema di 20 elettroni non interagenti 36
4.1.3 Sistema di 10 elettroni non interagenti 39
4.2 Analisi architetture e risultati 43
4.2.1 Sistema di singolo elettrone 43

4.2.2 Sistema di 20 elettroni non interagenti 49
4.2.3 Sistema di 10 elettroni non interagenti 53
4.3 Processo di minimizzazione 57
4.4 Applicazione dell'autoencoder variazionale 58

5 Conclusioni **61**

1. Introduzione

Uno dei problemi della fisica teorica moderna è la descrizione della struttura e dinamica di sistemi a molti elettroni interagenti, come nelle molecole complesse e nei solidi. Di particolare interesse è l'energia dello stato fondamentale, calcolabile in linea di principio attraverso la risoluzione dell'equazione di Schrödinger. Tuttavia, nella maggior parte dei casi di interesse pratico, l'elevato numero di gradi di libertà rende impossibile sia una soluzione analitica esatta, sia l'applicazione efficiente di metodi numerici basati sulla funzione d'onda. La teoria del funzionale della densità (DFT) [1] nasce per superare questa difficoltà, riformulando il problema in termini della densità elettronica, ovvero di una funzione delle sole tre variabili spaziali, riducendo il costo computazionale. La validità teorica è garantita dai teoremi di Hohenberg–Kohn, che dimostrano una relazione biunivoca tra densità elettronica dello stato fondamentale e l'energia del sistema, introducendo un funzionale della densità. La forma analitica di quest'ultimo non è però nota. Questa limitazione ha determinato lo sviluppo di due approcci computazionali distinti: il metodo di Kohn-Sham e la Orbital-Free DFT (OF-DFT). Nei recenti anni, è diventata inoltre di particolare interesse la possibilità di applicare algoritmi di apprendimento automatico nel contesto della DFT [2], con l'obiettivo di aumentare l'accuratezza a fronte di un minor dispendio computazionale. Esistono diversi approcci che sfruttano l'apprendimento automatico per calcolare l'energia dello stato fondamentale. In particolare, l'articolo di Snyder *et al.* (2012) [3] mostra l'applicazione dell'algoritmo *Kernel Ridge Regression* (KRR) per approssimare il funzionale dell'energia cinetica di un sistema unidimensionale di N fermioni non interagenti limitati in una regione di dimensione L, soggetti ad un potenziale esterno, raggiungendo accuratezze molto più elevate rispetto ad approssimazioni tradizionali. Il metodo è stato poi approfondito da Li *et al.* (2014) [4], analizzando l'accuratezza del modello al variare di *kernel* e iperparametri. Ulteriori studi sono stati realizzati utilizzando reti neurali convoluzionali per approssimare il funzionale [5], raggiungendo anche in questo caso accuratezza elevata. Un problema però evidenziato nei vari articoli, è il calcolo del gradiente poco accurato e rumoroso, necessario per il processo di minimizzazione utilizzato per ricavare la densità dello stato fondamentale. Per aggirare questo problema, Snyder *et al.* (2015) [6] hanno formulato un algoritmo, chiamato *Non Linear Gradient Denoising* (NLGD), per vincolare il processo di minimizzazione sulla varietà delle densità definita dai dati di addestramento, ottenendo così energie con errore inferiore rispetto al caso non vincolato. Ulteriori approcci sono introdotti da Brockherde *et al.* (2017) [7], i quali utilizzano modelli indipendenti di regressione lineare per apprendere direttamente la mappa tra il potenziale e i singoli coefficienti di una base della densità dello stato fondamentale associata, e Ryzco *et al.* (2019) [8], i quali utilizzano rete neurali profonde per ricavare la mappa tra potenziale e energia dello stato fondamentale. Infine, nell'articolo di Costa *et al.* (2024) [9] è mostrata la possibilità di sfruttare lo spazio latente di un autoencoder variazionale per applicare il

processo di minimizzazione per profili di densità compressi in poche variabili latenti.

La tesi ha come obiettivo introdurre alcuni di questi metodi, con particolare interesse riguardo modelli per approssimare il funzionale dell'energia cinetica, analizzandone le relative prestazioni. È divisa in quattro capitoli: i primi riguardano la teoria alla base della DFT e dell'apprendimento automatico, mentre in seguito sono poste le analisi e risultati dell'applicazione di reti neurali convoluzionali (CNN) ad un sistema con numero variabile di elettroni definito da un potenziale con parametri casuali. In particolare:

- **Capitolo 2**: Il secondo capitolo riguarda l'introduzione alla DFT. In esso, è definito l'Hamiltoniano di un sistema di N elettroni interagenti in presenza di un potenziale esterno e l'equazione agli autovalori per il calcolo dell'energia. È introdotto il principio della DFT, ovvero l'energia dello stato fondamentale è ricavabile attraverso un funzionale della densità elettronica, garantito dai due teoremi di Hohenberg-Kohn. Il primo dimostra la relazione biunivoca tra densità dello stato fondamentale e potenziale esterno, mentre il secondo dimostra l'esistenza di un funzionale dell'energia che assume il valore minimo quando valutato sulla densità dello stato fondamentale. In seguito, è definita la N-rappresentabilità e V-rappresentabilità, approfondendo quest'ultima per la definizione del funzionale. Sono poi presentati i metodi di Kohn-Sham e OF-DFT. In particolare, il metodo di Kohn-Sham reintroduce la funzione d'onda, approssimata ad un determinante di Slater dei orbitali di singola particella, per definire il funzionale cinetico. Il funzionale dell'energia totale è quindi scomposto in termine cinetico e potenziale, energia di Hartree e di scambio e correlazione. Sono date alcune approssimazioni possibili di quest'ultimo termine. Infine, il funzionale dell'energia è minimizzato per ricavare le equazioni di Khon-Sham. Il secondo metodo, OF-DFT, ha come obiettivo ridurre la complessità computazionale eliminando l'utilizzo di orbitali, riformulando il problema utilizzando approssimazioni dirette del termine cinetico. Sono trattate alcune possibili definizioni di quest'ultimo.

- **Capitolo 3**: Il terzo capitolo riguarda i fondamenti dell'apprendimento automatico. Sono inizialmente trattati due paradigmi di apprendimento: supervisionato e non supervisionato. È poi introdotto il processo di apprendimento, definendo formalmente l'output di un algoritmo come una funzione dipendente da un insieme di parametri e dai dati, e la relativa funzione di costo, che descrive le prestazioni del modello. Quest'ultima permette di ricondurre il processo di apprendimento come un problema di ottimizzazione, introducendo così l'algoritmo di discesa del gradiente. Sono inoltre trattatati l'underfitting e overfitting e i possibili metodi per riconoscere e mitigare queste problematiche. Sono presentati due modelli di apprendimento automatico: la rete neurale artificiale e autoencoder variazionale. La prima, si suddivide in Multilayer Perceptron (MLP), il quale è composto da un insieme di unità di elaborazione separate in livelli connessi tra loro, e rete neurale convoluzionale (CNN), la quale aggiunge ad un MLP blocchi che operano processi di convoluzione e pooling. Il secondo è un modello generativo, progettato per codificare dati in una rappresentazione continua e probabilistica e decodificarli in modo tale da generare nuovi dati coerenti con l'insieme di addestramento. Infine, sono introdotte le possibili applicazioni di algoritmi di apprendimento automatico nella DFT.

- **Capitolo 4**: Il quarto capitolo riguarda l'applicazione di CNN per approssimare il termine cinetico. Inizialmente, sono descritti i dati di addestramento comuni

a tutte le architetture di rete utilizzate. Sono presentati tre sistemi con, rispettivamente, 1, 20 e 10 elettroni confinati in una regione cubica di lato fissato dal raggio di Bohr, in presenza di un potenziale definito dalla somma di 10 gaussiane con parametri casuali. In seguito, è trattata l'analisi delle diverse architetture di CNN. La prima è incentrata sul sistema di singolo elettrone ed ha come obiettivo determinare la migliore architettura al variare del numero di blocchi convoluzionali e dimensione di output del blocco finale. La seconda analisi riguarda il sistema di 20 elettroni utilizzando la rete migliore definita nell'analisi del sistema precedente. La terza analisi riguarda il sistema di 10 elettroni, il quale presenta maggior informazione sulle energie, per mitigare i problemi riscontrati nel sistema di 20 elettroni. Infine, è trattato il processo di minimizzazione per ottenere la densità dello stato fondamentale dato un potenziale ed il possibile utilizzo di un autoencoder variazionale.

2. Teoria del funzionale della densità (DFT)

Si consideri un sistema di N elettroni interagenti soggetti ad un potenziale esterno. L'Hamiltoniano è della forma:

$$\hat{H} = \hat{T} + \hat{V} + \hat{U}, \tag{2.1}$$

dove i tre termini sono rispettivamente l'energia cinetica, il potenziale esterno ed il potenziale d'interazione tra le particelle. In unità atomiche, ovvero considerando $e = m_e = \hbar = 4\pi\epsilon_0 = 1$, rispettivamente la carica e massa dell'elettrone, la costante di Plank ridotta e la permittività del vuoto, gli operatori sono definiti:

$$\hat{T} = -\sum_{i=1}^{N} \frac{\nabla_i}{2}, \tag{2.2}$$

$$\hat{V} = \sum_{i=1}^{N} V(\mathbf{r_i}), \tag{2.3}$$

$$\hat{U} = \sum_{i,j=1 \ i<j}^{N} \frac{1}{|\mathbf{r_i} - \mathbf{r_j}|}. \tag{2.4}$$

Si ha un equazione agli autovalori di $\hat{H}$ del tipo:

$$\hat{H}\Psi(\mathbf{r}_1, ..., \mathbf{r}_N) = E\Psi(\mathbf{r}_1, ..., \mathbf{r}_N). \tag{2.5}$$

L'autofunzione Ψ è una funzione delle 4N variabili (3N variabili spaziali e N di spin). Per sistemi con un numero elevato di elettroni, tale dipendenza indica che non è possibile risolvere l'equazione di Schrödinger in modo esatto.

Il principio fondamentale della DFT è che qualsiasi proprietà di un sistema di molte particelle, in particolare l'energia, può essere rappresentata come un funzionale della densità dello stato fondamentale, definita come:

$$n[\mathbf{r}] = \sum_{\sigma} \int d\mathbf{r_2}...d\mathbf{r_N} |\Psi(\mathbf{r}, \mathbf{r_2}, ..., \mathbf{r_N})|^2, \tag{2.6}$$

dove σ rappresenta la variabile di spin. A differenza della funzione d'onda, la densità elettronica dipende solo da 3 variabili spaziali e di spin (x, y, z, σ), indipendentemente dal numero di elettroni del sistema. Ciò rende possibile l'utilizzo di metodi numerici per la risoluzione del problema a molti corpi anche per sistemi con N elevato.
Due teoremi sono alla base della DFT, introdotti nella seguente sezione.

2.1 Teoremi di Hohenberg-Kohn

I teoremi di Hohenberg-Kohn [10] dimostrano la relazione biunivoca tra densità elettronica e energia del sistema.

Teorema 2.1. *La densità elettronica dello stato fondamentale $n_0(\mathbf{r})$ determina - a meno di una costante additiva - il potenziale esterno V. Le proprietà dello stato fondamentale sono quindi funzionali della densità elettronica $n_0(\mathbf{r})$.*

Dimostrazione. Si procede *per contraddizione*. Si considerino due potenziali V e V' tali che $\hat{H} = \hat{T} + \hat{V}$ e $\hat{H}' = \hat{T} + \hat{V}'$ e che diano luogo a due funzioni d'onda dello stato fondamentale Ψ e Ψ' e energia E_0 e E_0' con la stessa densità elettronica $n_0(\mathbf{r})$. Tranne nel caso in cui $V - V' = \text{const}$, Ψ e Ψ' sono diverse, poiché soddisfano equazioni di Schrödinger differenti. Si ha, considerando $\hat{H}' = \hat{H} - V + V'$ ed il principio variazionale di Rayleigh-Ritz:

$$E_0' = \langle \Psi' | \hat{H}' | \Psi' \rangle < \langle \Psi | \hat{H}' | \Psi \rangle = \langle \Psi | \hat{H} + V' - V | \Psi \rangle; \tag{2.7}$$

è quindi possibile scrivere:

$$E_0' < E_0 + \int [V'(\mathbf{r}) - V(\mathbf{r})] n_0(\mathbf{r}) d\mathbf{r}; \tag{2.8}$$

in modo analogo si ha:

$$E_0 < E_0' + \int [V(\mathbf{r}) - V'(\mathbf{r})] n_0(\mathbf{r}) d\mathbf{r}. \tag{2.9}$$

Sommando la 2.8 con 2.9 si arriva ad una contraddizione:

$$E_0 + E_0' < E_0 + E_0'. \tag{2.10}$$

Quindi la densità elettronica dello stato fondamentale determina in modo univoco il potenziale esterno. □

Teorema 2.2. *Dato un potenziale esterno V ed un potenziale d'interazione U, si definisce il funzionale energia:*

$$E[n(\mathbf{r})] = F[n(\mathbf{r})] + \int V(\mathbf{r}) n(\mathbf{r}) d\mathbf{r}, \tag{2.11}$$

dove $F[n(\mathbf{r})]$ è detto funzionale universale.
Il funzionale $E[n(\mathbf{r})]$ assume il suo valore minimo in corrispondenza della densità elettronica dello stato fondamentale, ovvero quando $n(\mathbf{r}) = n_0(\mathbf{r})$. Data una generica densità $n(\mathbf{r})$ tale che sia N-rappresentabile e V-rappresentabile[1] si ha quindi:

$$E[n(\mathbf{r})] \geq E[n_0(\mathbf{r})] = E_0. \tag{2.12}$$

[1] Una densità è detta N-rappresentabile se corrisponde ad una funzione d'onda antisimmetrica di N particelle, mentre è V-rappresentabile se corrisponde allo stato fondamentale per un opportuno potenziale esterno.

Dimostrazione. Si consideri un Hamiltoniano del tipo:

$$\hat{H} = \hat{T} + \hat{V} + \hat{U}. \tag{2.13}$$

Si considerino inoltre la densità dello stato fondamentale $n_0(\mathbf{r})$ associata alla funzione d'onda Ψ_0 ed una generica densità di prova $n(\mathbf{r})$ corrispondente alla funzione Ψ. La seguente definizione del funzionale universale è approfondita nella sezione (2.2):

$$F[n(\mathbf{r})] = \min_{\Psi \to n(\mathbf{r})} \langle \Psi | \hat{T} + \hat{U} | \Psi \rangle. \tag{2.14}$$

Applicando il principio variazionale di Rayligh-Ritz si ha:

$$E_0 = \langle \Psi_0 | \hat{H} | \Psi_0 \rangle \leq \langle \Psi | \hat{H} | \Psi \rangle. \tag{2.15}$$

Scomponendo l'operatore Hamiltoniano e utilizzando la definizione del funzionale universale, il termine a destra si può riscrivere come:

$$\langle \Psi | \hat{H} | \Psi \rangle = \langle \Psi | \hat{T} + \hat{U} | \Psi \rangle + \langle \Psi | \hat{V} | \Psi \rangle = F[n(\mathbf{r})] + \int V(\mathbf{r}) n(\mathbf{r}) d\mathbf{r}. \tag{2.16}$$

Richiamando la definizione del funzionale energia $E[n(\mathbf{r})]$ si ha:

$$E_0 \leq E[n(\mathbf{r})]. \tag{2.17}$$

□

I due teoremi ammettono l'esistenza del funzionale energia $E[n(\mathbf{r})]$ e la sua relazione con la densità elettronica dello stato fondamentale $n_0(\mathbf{r})$, ma la forma esatta del funzionale non è ricavabile. È necessario quindi ricorrere a metodi approssimati, come l'approccio di Kohn-Sham [11] e Orbital-Free DFT [12].

2.2 Problema della V-rappresentabilità

Una delle limitazione del funzionale $F[n(\mathbf{r})]$ definito nella teoria di Hohenberg e Kohn è che non è definito per densità $n(\mathbf{r})$ non V-rappresentabili . In particolare, non è dimostrato che una qualsiasi densità tale che $\int n(\mathbf{r}) d\mathbf{r} =$ intero, corrisponda ad un potenziale esterno V. L'applicazione del principio variazionale potrebbe quindi restituire una densità per cui il funzionale $F[n(\mathbf{r})]$ non è definito. Esiste però un funzionale $Q[n(\mathbf{r})]$ che restituisce la somma del termine cinetico e dell'energia repulsiva elettrone-elettrone estendendo il dominio di $F[n(\mathbf{r})]$ a tutte le densità N-rappresentabili [13]. Inoltre, per tutte le densità V-rappresentabili si ha:

$$F[n(\mathbf{r})] = Q[n(\mathbf{r})]. \tag{2.18}$$

Il funzionale universale per le densità N-rappresentabili è definito come:

$$Q[n(\mathbf{r})] = \min_{\Psi \to n(\mathbf{r})} \langle \Psi | \hat{T} + \hat{U} | \Psi \rangle, \tag{2.19}$$

dove Ψ è la funzione d'onda antisimmetrica associata alla densità di prova $n(\mathbf{r})$ non necessariamente V-rappresentabile.

È dimostrato che il funzionale $Q[n(\mathbf{r})]$ soddisfa i seguenti teoremi:

Teorema 2.3.

$$Q[n(\mathbf{r})] + \int V(\mathbf{r})n(\mathbf{r})d\mathbf{r} \geq E_0 \tag{2.20}$$

Teorema 2.4.

$$Q[n_0(\mathbf{r})] + \int V(\mathbf{r})n_0(\mathbf{r})d\mathbf{r} = E_0 \tag{2.21}$$

dove $n_0(\mathbf{r})$ e E_0 sono rispettivamente la densità e l'energia dello stato fondamentale.

$Q[n_0(\mathbf{r})]$ è quindi un valido funzionale universale esteso a tutte le funzioni N-rappresentabili a cui è possibile applicare il principio variazionale, risolvendo così il problema della V-rappresentabilità.

2.3 Metodo di Kohn-Sham

Una delle difficoltà della definizione del funzionale $E[n(\mathbf{r})]$ risiede nel ricavare la forma esplicita del termine cinetico definito come:

$$T[n(\mathbf{r})] := \langle \Psi | \hat{T} | \Psi \rangle. \tag{2.22}$$

L'idea di Kohn e Sham è quella di assumere l'esistenza di un sistema di elettroni non interagenti che diano luogo alla stessa densità elettronica dello stato fondamentale del sistema interagente.

2.3.1 Equazioni di Kohn-Sham

In questo modo è possibile rappresentare la funzione d'onda Ψ come un determinante di Slater, ovvero:

$$\Psi_s(\mathbf{r}_1, \ldots, \mathbf{r}_N) = \frac{1}{\sqrt{N!}} \begin{vmatrix} \psi_1(\mathbf{r}_1) & \psi_2(\mathbf{r}_1) & \cdots & \psi_N(\mathbf{r}_1) \\ \psi_1(\mathbf{r}_2) & \psi_2(\mathbf{r}_2) & \cdots & \psi_N(\mathbf{r}_2) \\ \vdots & \vdots & \ddots & \vdots \\ \psi_1(\mathbf{r}_N) & \psi_2(\mathbf{r}_N) & \cdots & \psi_N(\mathbf{r}_N) \end{vmatrix} \tag{2.23}$$

dove gli ψ_i sono gli autostati dell'Hamiltoniano di singolo elettrone. Utilizzando Ψ_s nella definizione del termine cinetico (2.22), si ha:

$$T_s[n(\mathbf{r})] = \frac{1}{2} \sum_{i=1}^{N} \int \Psi_i^*(\mathbf{r}) \nabla^2 \Psi_i(\mathbf{r}) d\mathbf{r}. \tag{2.24}$$

Inoltre si definisce l'energia di repulsione di Coulomb classica, detta *energia di Hartree*:

$$E_H[n(\mathbf{r})] := \frac{1}{2} \int \int \frac{n(\mathbf{r})n(\mathbf{r}')}{|\mathbf{r} - \mathbf{r}|} d\mathbf{r} d\mathbf{r}'. \tag{2.25}$$

Il funzionale energia definito in (2.11) è riscritto come:

$$E_{KS}[n(\mathbf{r})] = T_s[n(\mathbf{r})] + E_H[n(\mathbf{r})] + E_{XC}[n(\mathbf{r})] + \int V(\mathbf{r})n(\mathbf{r})d\mathbf{r}. \tag{2.26}$$

Il termine E_{XC}, detto *energia di scambio e correlazione*, comprende la differenza tra l'energia cinetica del sistema reale interagente ed il sistema fittizio $(T - T_s)$, sommato

al contributo dell'interazione elettrone-elettrone non descritta dal termine di Hartree. Si può quindi scrivere il funzionale come:

$$E_{XC}[n(\mathbf{r})] = T[n(\mathbf{r})] - T_s[n(\mathbf{r})] + E_U[n(\mathbf{r})] - E_H[n(\mathbf{r})], \tag{2.27}$$

dove il termine $E_U = \langle\Psi|\hat{U}|\Psi\rangle$ è il valore di aspettazione del termine di interazione elettrone-elettrone.

Per il teorema (2.2), il funzionale E_{KS} assume il suo valore minimo quando $n(\mathbf{r})$ è la densità dello stato fondamentale. La soluzione per l'energia può essere quindi ricondotta ad un problema di minimizzazione vincolata per E_{KS}. Considerando che il funzionale T_s è definito in termini di funzione d'onda, è possibile considerare la variazione di E_{KS} rispetto alla generica funzione d'onda ψ_i, considerando il seguente vincolo di ortonormalità:

$$\langle\psi_i|\psi_j\rangle = \delta_{i,j}. \tag{2.28}$$

Applicando il metodo dei moltiplicatori di Lagrange si ha:

$$\delta\left[E_{KS}[n(\mathbf{r})] - \sum_{i=1}^{N}\epsilon_i\left(\int\psi_i^*(\mathbf{r})\psi_i(\mathbf{r})d\mathbf{r} - 1\right)\right] = 0. \tag{2.29}$$

La variazione di E_{KS} rispetto ad una generica funzione ψ_i^* è:

$$\frac{\delta E_{\mathrm{KS}}}{\delta\psi_i^*(\mathbf{r})} = \frac{\delta T_s}{\delta\psi_i^*(\mathbf{r})} + \left[\frac{\delta E_{\mathrm{V}}}{\delta n(\mathbf{r})} + \frac{\delta E_{\mathrm{H}}}{\delta n(\mathbf{r})} + \frac{\delta E_{\mathrm{XC}}}{\delta n(\mathbf{r})}\right]\frac{\delta n(\mathbf{r})}{\delta\psi_i^*(\mathbf{r})}. \tag{2.30}$$

Considerando le definizioni del termine cinetico (2.22) e della densità elettronica (2.6) e le regole di derivazione di funzionali, si ha:

$$\frac{\delta T_s}{\delta\psi_i^*(\mathbf{r})} = -\frac{1}{2}\nabla^2\psi_i(\mathbf{r}); \qquad \frac{\delta n(\mathbf{r})}{\delta\psi_i^*(\mathbf{r})} = \psi_i(\mathbf{r}), \tag{2.31}$$

Inserendo ciò nella (2.29) si arriva ad un set di equazioni, dette *equazioni di Kohn-Sham*, del tipo:

$$\left(H_{KS} - \epsilon_i\right)\psi_i(\mathbf{r}) = \psi_i(\mathbf{r}), \tag{2.32}$$

dove

$$H_{KS} = -\frac{\nabla^2}{2} + V_{KS}(\mathbf{r}) = -\frac{\nabla^2}{2} + V(\mathbf{r}) + \int\frac{n(\mathbf{r}')}{|\mathbf{r}-\mathbf{r}'|}d\mathbf{r}' + \frac{\delta E_{XC}}{\delta n(\mathbf{r})}. \tag{2.33}$$

2.3.2 Soluzione delle equazioni di Kohn-Sham

L'equazioni di Kohn-Sham sono un set di equazioni dipendenti dalla forma del potenziale V_{KS}, il quale è definito dalla densità elettronica $n(\mathbf{r})$. Per poter calcolare gli autovalori ϵ_i e le autofunzioni associate ψ_i si deve quindi utilizzare un metodo auto-consistente. Il processo è schematizzato in figura (2.1).

Inizialmente, si definisce un set di funzioni di prova ψ_i^{in} che danno luogo ad una densità elettronica iniziale $n^{in}(\mathbf{r})$. Sulla base di tale densità, si calcola il potenziale efficace $V_{KS}[n^{in}(\mathbf{r})]$ e si risolvono le equazioni di Kohn-Sham. Dagli autostati risultanti

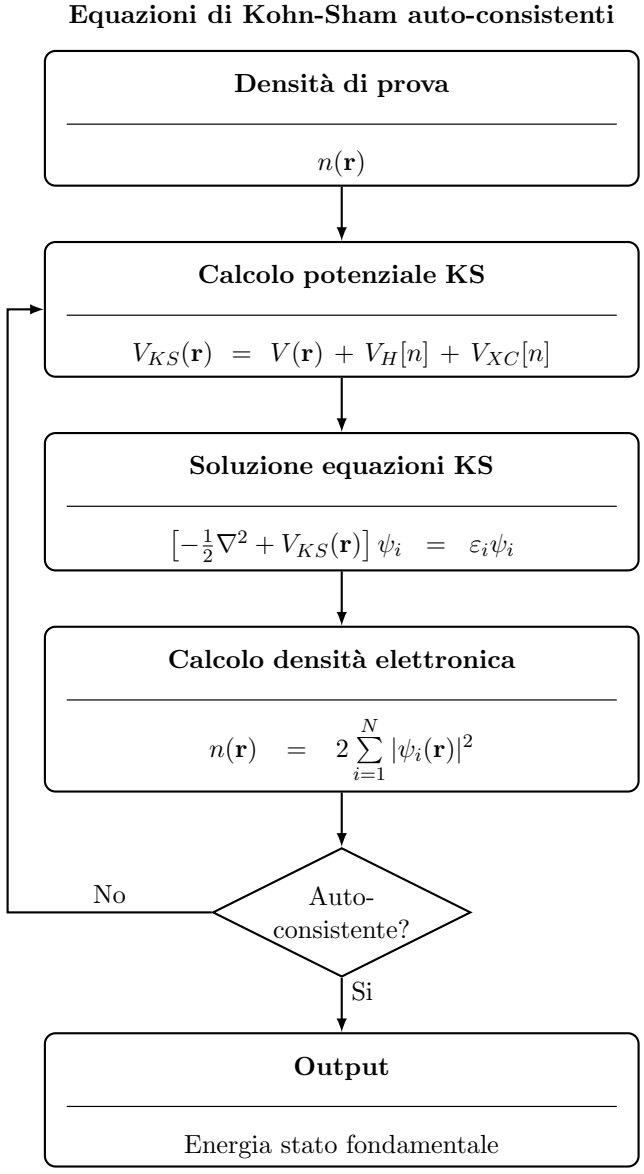


Figura 2.1: Rappresentazione schematica del loop auto-consistente per la soluzione delle equazioni KS.

si calcola una nuova densità di output $n^{out}(\mathbf{r})$. Se quest'ultima differisce dalla densità di ingresso oltre una soglia di tolleranza prefissata, il ciclo viene reiterato aggiornando la densità iniziale fino al raggiungimento della convergenza. La nuova densità iniziale non può essere uguale a $n^{out}(\mathbf{r})$, poiché la variazione sarebbe troppo elevata e porterebbe ad instabilità numeriche. Il metodo più semplice è una combinazione lineare di $n^{in}(\mathbf{r})$ e $n^{out}(\mathbf{r})$. Allo step i-esimo si ha:

$$n_{i+1}^{in} = \alpha n_i^{out} + (1-\alpha)n_i^{in} \tag{2.34}$$

dove $\alpha \in [0,1]$ è un parametro in generale dipendete dal sistema in esame. In particolare, valori elevati di α possono essere utilizzati per sistemi con forti legami, come

gli isolanti, mentre per i metalli è necessario utilizzare valori piccoli per garantire la convergenza.

Infine, raggiunta la convergenza, l'energia dello stato fondamentale è calcolata valutando il funzionale $E[n(\mathbf{r})]$ sulla densità elettronica finale.

2.3.3 Significato autovalori

Nelle equazioni di Kohn-Sham, sebbene gli autovalori ϵ_i appaiono formalmente analoghi alle energie degli orbitali elettronici, essi non possiedono in generale un significato fisico diretto in termini di energie di rimozione o aggiunta di elettroni, a differenza di quanto avviene nella teoria di Hartree-Fock (REF). Vi è un unica eccezione riguardo l'autovalore più elevato, il quale rappresenta l'opposto del potenziale di ionizzazione del sistema $-I$. Inoltre, lo spettro degli autovalori di Kohn-Sham fornisce una base di partenza per teorie più avanzate per il calcolo degli stati eccitati.

2.3.4 Termine di scambio e correlazione

Tutto ciò che abbiamo trattato fino ad ora permetterebbe in linea principio di calcolare l'energia esatta dello stato fondamentale di un sistema a molti corpi interagenti. Tuttavia, non è possibile determinare la forma esatta del funzionale E_{XC}. Sono quindi necessarie delle approssimazioni più o meno complesse a seconda del sistema trattato.

Il contributo di energia dato da E_{XC} è dovuto alla *buca di scambio e correlazione*, ovvero la ridotta probabilità di trovare un elettrone nelle vicinanze di un altro elettrone per via del principio di esclusione di Pauli (contributo di scambio) e la repulsione elettrostatica non trattata dal potenziale di Hartree (contributo di correlazione).

Le seguenti approssimazioni permettono di descrivere questo contributo in modo sempre più accurato, aumentando però il costo computazionale:

- **Approssimazione Densità Locale (LDA)**

  Si assume che la densità elettronica in ogni punto è uguale a quella di un gas di elettroni omogeneo. In questo modo è possibile scrivere il funzionale come:

  $$E_{XC}^{LDA}[n(\mathbf{r})] = \int n(\mathbf{r})\epsilon_{xc}([n(\mathbf{r})], \mathbf{r})d\mathbf{r}, \tag{2.35}$$

  dove $\epsilon_{xc}([n(\mathbf{r})], \mathbf{r})$ è l'energia di correlazione e scambio per elettrone, ricavabile dalla teoria di un gas di elettroni omogeneo, in un punto $\mathbf{r}$ valutato con una certa densità $n(\mathbf{r})$. L'approssimazione è detta locale perché non vi sono dipendenze dal gradiente della densità $\nabla n(\mathbf{r})$.

  In termini di calcolo è l'approssimazione meno costosa, riuscendo comunque ad avere buoni risultati nei solidi con densità elettronica poco variabile.

- **Approssimazione Generalized-Gradient (GGAs)**

  Per aumentare l'accuratezza dell'approssimazione è necessaria l'introduzione del gradiente della densità $\nabla n(\mathbf{r})$. Un primo approccio è quello di definire il funzionale in termine di espansione in serie di E_{XC}, dove il primo termine dell'espansione è il funzionale dato da LDA. Ciò comporta però l'assunzione che la densità vari lentamente, non sempre accurata, portando quindi a risultati non migliori rispetto a LDA.

Il termine *GGA* denota una famiglia di possibili funzioni tali da modificare il comportamento per grandi gradienti in modo tale da avere risultati consistenti. Il funzionale E_{XC} è scritto nella forma:

$$E_{XC}^{GGA}[n(\mathbf{r})] = \int n(\mathbf{r})\epsilon_{xc}([n(\mathbf{r})], [\nabla n(\mathbf{r})], \mathbf{r})d\mathbf{r}, \tag{2.36}$$

Questa approssimazione ha un costo computazionale più elevato rispetto a LDA, ma permette di avere risultati migliori sistemi con densità elettronica variabile.

2.4 Orbital-Free DFT

La reintroduzione degli orbitali nel metodo di Kohn-Sham per il calcolo del funzionale dell'energia cinetica permette di ricavare le proprietà dello stato fondamentale del sistema interagente. Tuttavia, il costo computazionale degli algoritmi necessari per la diagonalizzazione dell'Hamiltoniano H_{KS} nelle equazione (2.32) scala come $\mathcal{O}(N^3)$, dove N è il numero di elettroni del sistema. Tale dipendenza rende proibitivo l'utilizzo del metodo per sistemi con N elevato.

Orbital-Free DFT (OF-DFT) riformula il problema calcolando direttamente il termine cinetico per elettroni non interagenti T_s in termini della densità elettronica $n(\mathbf{r})$, rimuovendo così la dipendenza dagli orbitali e rendendo il metodo più efficiente rispetto a Kohn-Sham. Sebbene il funzionale energia $E[n(\mathbf{r})]$ mantiene formalmente la struttura della (2.26), l'assenza di una forma analitica esatta per l'energia cinetica in funzione della sola densità rende necessario l'utilizzo di approssimazioni. Come nel caso del termine di scambio e correlazione E_{XC}, vi sono diverse possibili approssimazioni utili a seconda del sistema trattato:

- **Modello di Thomas-Fermi**

  Per sistemi in cui la densità elettronica varia lentamente, è possibile applicare l'espressione esatta dell'energia cinetica per un gas di elettroni omogeneo localmente ed integrare su tutto lo spazio. Il funzionale assume la forma:

  $$T_{TF}[n(\mathbf{r})] = C_{TF} \int n^{5/3}(\mathbf{r})d\mathbf{r}, \tag{2.37}$$

  dove $C_{TF} = \frac{3}{10}(3\pi^2)^{2/3}$ in unità atomiche.

  Nonostante sia computazionalmente efficiente, molti sistemi non sono descritti adeguatamente poiché presentano forti gradienti di densità, come nella regione vicina ad un nucleo per un atomo isolato o sistemi legati come molecole.

- **Modello di Thomas-Fermi-von Weizsäcker**

  Un primo miglioramento è introdotto da *von Weizsäcker*, il quale incorpora la non uniformità della densità elettronica con l'introduzione del gradiente della densità. L'energia cinetica totale è:

  $$T_{TFW}[n(\mathbf{r})] = T_{TF}[n(\mathbf{r})] + \lambda T_W[n(\mathbf{r})], \tag{2.38}$$

  dove il termine di correzione di von Weizsäcker è dato da:

$$T_W[\mathbf{r}] = \frac{1}{8}\int \frac{|\nabla n(\mathbf{r})|^2}{n(\mathbf{r})} d\mathbf{r}. \tag{2.39}$$

Il parametro λ dipende dal sistema trattato. Ad esempio, valori vicino a $\lambda = 1$ funzionano bene nel caso di densità molto variabili, mentre valori come $\lambda = \frac{1}{9}$ comportano risultati migliori rispetto al funzionale TF nel caso di densità poco variabili.

- **Funzionali non locali**

  L'introduzione di funzionali non locali per la definizione di T_s permette di incorporare correttamente la risposta lineare del sistema interagente [14]. Il funzionale dell'energia cinetica è dato da:

  $$T_s[\mathbf{r}] = T_{TF}[n(\mathbf{r})] + T_W[n(\mathbf{r})] + T_{nl}[n(\mathbf{r})], \tag{2.40}$$

  dove T_{TF} e T_W sono i termini già definiti, e il termine T_{nl} non locale assume la forma:

  $$\int\int n^{\alpha}(\mathbf{r}) K(\mathbf{r}, \mathbf{r}', n) n^{\beta}(\mathbf{r}') d\mathbf{r} d\mathbf{r}'. \tag{2.41}$$

  L'introduzione di tale contributo permette di superare le limitazioni intrinseche delle approssimazioni locali, migliorando significativamente la capacità predittiva del modello nella descrizione delle proprietà del sistema.

Nonostante i tentativi di costruire una forma analitica del funzionale dell'energia cinetica dipendente dalla sola densità elettronica, la mancanza di un funzionale universale porta limitazioni nell'utilizzo della OF-DFT per sistemi con forti eterogeneità spaziali o legami chimici complessi. Un esempio è la difficoltà nel riprodurre la struttura a shell di nuclei e atomi senza introdurre termini correttivi dipendenti dagli orbitali (REF). Per superare tali criticità, l'idea è di utilizzare modelli di apprendimento automatico addestrati su dataset di riferimento per poter approssimare la mappa tra densità elettronica $n(\mathbf{r})$ e termine cinetico T_s.

3. Apprendimento automatico

L'apprendimento automatico [15] è il sottoinsieme dell'intelligenza artificiale basato su algoritmi in grado di apprendere i modelli dai dati di addestramento e, successivamente, fare previsioni accurate sui nuovi dati. A differenza di algoritmi tradizionali, dove si definiscono regole per manipolare i dati di input per avere nuovi dati in output, gli algoritmi d'apprendimento automatico ricavano modelli e informazioni da un dataset iniziale in modo tale da determinare le regole necessarie per realizzare previsioni su nuovi dati di input.

3.1 Paradigmi di apprendimento

Esistono diverse macrocategorie di algoritmi d'apprendimento automatico [16]. In questa sezione vengono trattati, in particolare, l'apprendimento non supervisionato [17] e quello supervisionato [18].

3.1.1 Apprendimento non supervisionato

L'apprendimento non supervisionato permette di determinare pattern e strutture nascoste in un insieme di dati privi di etichette. Un dataset contenente N dati è rappresentato da vettori D-dimensionali $\{\mathbf{X_i}\}_{i=1}^{N}$, dove le componenti sono detti descrittori. I descrittori sono valori numerici che permetto di codificare l'informazione di un determinato dato. Gli obiettivi dell'apprendimento non supervisionato sono:

- **Analisi dei Cluster**

  L'analisi dei cluster organizza automaticamente i dati in gruppi a seconda delle loro similarità. L'obiettivo è garantire che i dati all'interno dello stesso gruppo siano più simili tra loro rispetto a quelli di gruppi diversi, in modo tale da determinare raggruppamenti nascosti in dataset complessi.

- **Riduzione della dimensionalità**

  Gli algoritmi per la riduzione della dimensionalità permettono di ridurre il numero di descrittori necessari per un dato minimizzando la perdita d'informazione, semplificando l'analisi e visualizzazione di dati complessi.

- **Modelli generativi**

  L'apprendimento generativo si pone l'obiettivo di modellizzare la distribuzione di probabilità sottostante del dataset per realizzare nuove istanze di dati che presentino le medesime caratteristiche statistiche di quelle originali.

3.1.2 Apprendimento supervisionato

A differenza dell'apprendimento non supervisionato, in questo caso l'insieme dei dati d'addestramento è definito da vettori D-dimensionali e da etichette $\{(\mathbf{x}_i, y_i)\}_{i=1}^{N}$. L'obiettivo dell'apprendimento supervisionato è di costruire un modello in grado di riprodurre le etichette note e realizzare predizioni accurate su nuovi dati. L'apprendimento supervisionato è applicato sue due problemi principali:

- **Classificazione**

  Le etichette sono variabili discrete che determinano a quale categoria appartiene il dato associato. L'algoritmo analizza i descrittori dei dati etichettati per stabilire dei confini di decisione dividendo lo spazio D-dimensionale in regioni distinte. L'algoritmo assegna la categoria ad un nuovo dato $\mathbf{x}$ a seconda della regione in cui si posiziona.

- **Regressione**

  Le etichette sono variabili continue che determinano l'output di una funzione applicata ad un determinato dato. L'obiettivo è di predire il valore numerico di output su un nuovo dato $\mathbf{x}$ di input a seconda della relazioni tra dato e etichetta del dataset iniziale.

3.2 Processo di apprendimento

L'output di un algoritmo di apprendimento automatico può essere formalmente definito come il valore di una certa funzione $f(\mathbf{w}, \mathbf{x})$, dove $\mathbf{w} = (w_1, w_2, ..., w_M)$ è un insieme di parametri liberi detti *pesi*, valutata in un dato $\mathbf{x}$. Il processo di apprendimento ha come obiettivo ricavare i corretti valori $\mathbf{w}$ in modo tale da avere un output coerente con i dati utilizzati per l'allenamento. In particolare, si definisce la funzione di costo come:

$$L(\mathbf{w}) = \frac{1}{N} \sum_{i=1}^{N} \mathcal{L}(\mathbf{x}_i, f(\mathbf{w}, \mathbf{x}_i)) \tag{3.1}$$

dove $\mathcal{L}(\mathbf{x}_i, f(\mathbf{w}, \mathbf{x}_i))$ è una funzione dipendente dal tipo di problema trattato che descrive le prestazioni del modello e N è il numero di dati presenti nell'insieme di addestramento. La funzione di costo presenta un minimo quando i pesi $\mathbf{w}$ sono i valori corretti per definire la $f(\mathbf{w}, \mathbf{x})$. Il processo di apprendimento è quindi ricondotto ad un problema di ottimizzazione.

3.2.1 Algoritmo di discesa del gradiente

L'algoritmo di discesa del gradiente è un metodo di ottimizzazione iterativo del primo ordine per la ricerca di minimi di una funzione di costo $L(\mathbf{w})$ definita e differenziabile. Il metodo si basa sulla proprietà del vettore gradiente $\nabla_{\mathbf{w}} L(\mathbf{w})$ di indicare la direzione e il verso di massima crescita locale della funzione. Di conseguenza, la direzione dello spostamento che garantisce la massima decrescita locale è definita dal vettore opposto al gradiente, $-\nabla_{\mathbf{w}} L(\mathbf{w})$.

Allo step iniziale si attribuiscono valori casuali ai pesi e si applica allo step j-esimo il seguente procedimento:

$$\mathbf{w}^{j+1} = \mathbf{w}^{j} - \eta \nabla_{\mathbf{w}} L(\mathbf{w}^{j}), \tag{3.2}$$

dove η, detto tasso di apprendimento, è un parametro che determina l'ampiezza del passo che l'algoritmo compie ad ogni iterazione per aggiornare i pesi. Valori troppo elevati di η portano a fenomeni di *overshooting*, dove l'algoritmo non converge verso il minimo ma oscilla in un intorno di esso. Valori troppo bassi di η garantiscono la convergenza verso il minimo, ma potrebbero richiedere un numero di iterazioni troppo elevato, aumentando il dispendio computazionale.

L'algoritmo, inoltre, non assicura che il punto di stazionarietà raggiunto sia un minimo globale, con il rischio di convergere verso una configurazione dei pesi non ottimale. Un metodo utilizzato per attenuare questa problematica è l'algoritmo stocastico di discesa del gradiente, dove il gradiente ora non è calcolato sull'insieme totale dei dati $\mathbf{x}$, ma su un sottoinsieme molto minore di quello iniziale. In questo modo, oltre a migliorare l'efficienza, si introduce un rumore stocastico che può permettere al processo di superare minimi locali poco profondi.

3.2.2 Problema di underfitting e overfitting

Il processo di apprendimento ha come obiettivo la corretta generalizzazione dell'output del modello di apprendimento automatico su nuovi dati non appartenenti all'insieme di allenamento. Possono verificarsi situazioni in cui il modello è troppo semplice per descrive la struttura di dati complessi, portando al fenomeno dell'*undefitting*, oppure troppo preciso, imparando anche il rumore dei dati di allenamento, portando al fenomeno dell'*overfitting*. Il bias e la varianza sono due concetti utili a descrivere l'errore dell'output. Il bias si riferisce all'errore causato dalla semplificazione del modello, mentre la varianza si riferisce all'errore dato dall'elevata sensibilità all'insieme dei dati di allenamento. L'ottimizzazione dei parametri che definiscono il funzionamento del modello, detti *iperparametri*, è fondamentale per minimizzare bias e varianza.

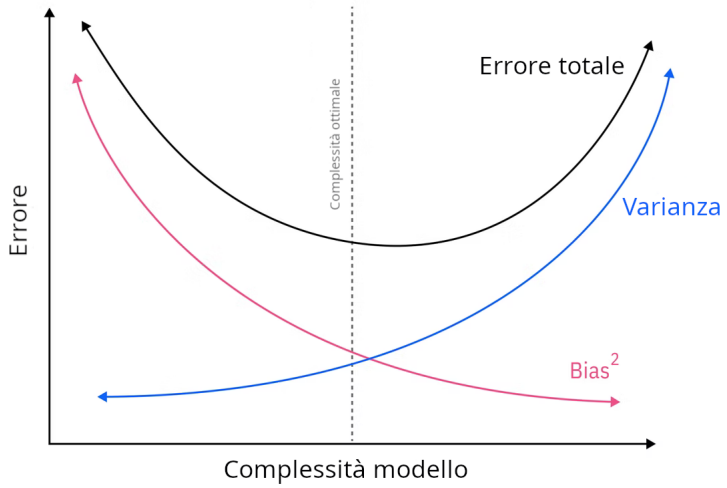


Figura 3.1: Relazione tra complessità del modello e errore di output. Immagine tratta da [19].

L'analisi delle prestazioni di un modello permette di riconoscere e mitigare queste problematiche utilizzando metriche di errore. L'insieme dei dati iniziale è suddiviso in tre sottoinsiemi:

- **Set di addestramento**

  Rappresenta solitamente il 70% dell'insieme iniziale. È utilizzato per l'ottimizzazione dei pesi $\mathbf{w}$ tramite la minimizzazione della funzione di costo.

- **Set di validazione**

  Rappresenta circa il 15% dell'insieme iniziale. È utilizzato per verificare l'errore del modello al variare degli iperparametri in modo tale da scegliere i valori migliori.

- **Set di test**

  Rappresenta il restante 15% dell'insieme iniziale. È utilizzato una sola volta per fornire una stima dell'errore su dati mai utilizzati.

Il modello è in overfitting se ha un basso errore utilizzando il set di addestramento e un elevato errore utilizzando il set di test, mentre è in underfitting se ha un elevato errore sia usando il set di addestramento che il set di test.

Nel caso dell'apprendimento supervisionato nei problemi di regressione è utile definire la seguente metrica:

$$R^2 = 1 - \frac{\sum_{i=1}^{N}(y_i - f(\mathbf{w}, \mathbf{x}_i))^2}{\sum_{i=1}^{N}(y_i - \bar{y})^2} \tag{3.3}$$

dove $\mathbf{x}_i$ e y_i sono rispettivamente dati e etichette, la $f(\mathbf{w}, \mathbf{x}_i)$ è l'output del modello valutato in $\mathbf{x}_i$ e $\bar{y}$ è il valor medio delle etichette.

Quando $R^2 = 1$ si ha $f(\mathbf{w}, \mathbf{x}_i) = y_i \ \forall i$, ovvero il modello restituisce esattamente l'etichetta associata al dato $\mathbf{x}_i$, mentre con $R^2 = 0$ si ha $f(\mathbf{w}, \mathbf{x}_i) = \bar{y} \ \forall i$, ovvero per qualsiasi valore di $\mathbf{x}_i$ il modello dà come output il valor medio delle etichette.

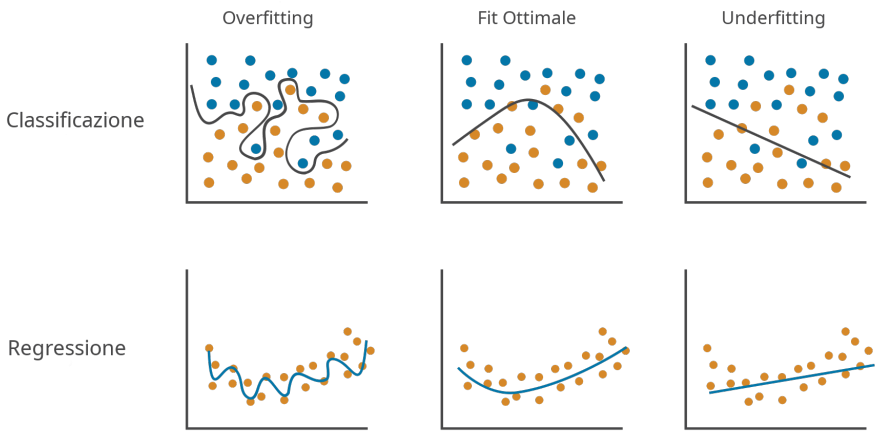


Figura 3.2: Generalizzazione nei problemi di classificazione e regressione. Immagine tratta da [20].

Esistono diverse strategie volte a ridurre questi fenomeni, in particolare si aumenta o diminuisce la complessità del modello variando gli *iperparametri* e si aggiunge un fattore di regolarizzazione nella funzione di costo, in modo tale da penalizzare modelli con valori elevati dei pesi. Un esempio è la regolarizzazione L_2:

$$L_2(\mathbf{w}) = \frac{\lambda}{2N} \sum_{j=1}^{M} w_j^2, \tag{3.4}$$

dove N è il numero di dati di allenamento, M è il numero di pesi e λ è un *iperparametro* che determina l'intensità della regolarizzazione. La scelta corretta di λ permette di ridurre l'errore del modello nel set di test, mentre un valore errato può aumentare l'underfitting o overfitting.

3.3 Reti neurali artificiali

Una rete neurale artificiale [21] è un modello di apprendimento automatico basato sul funzionamento semplificato del cervello umano. L'utilità nel contesto della OF-DFT è data dagli articoli [22, 23] in cui è dimostrato che una qualsiasi funzione continua vettoriale a più variabili è approssimabile da una rete neurale sufficientemente profonda. In particolare è possibile approssimare il funzionale dell'energia cinetica T_s. In questa sezione viene trattato il modello *Multilayer Perceptron* e la rete neurale convoluzionale.

3.3.1 Multilayer Perceptron (MLP)

Le reti neurali MLP sono composte da un insieme di unità di elaborazione dette *neuroni* distribuiti in strati e collegati tra loro. Ad un singolo neurone è associato un insieme di pesi, dipendente dal numero di input, in modo tale da eseguire una combinazione lineare dei valori di input per avere un singolo valore in output:

$$a = h\left(\sum_{k=1}^{N} w_k x_k + b_0\right), \tag{3.5}$$

dove a è l'output del neurone, w_k è il peso associato all'input x_k e b_0 è un valore detto di bias, mentre $h(\mathbf{x})$ è una funzione non lineare, detta funzione di attivazione, che determina il valore finale di output dei neuroni. Esistono diverse definizioni della *funzione di attivazione*, la più utilizzata è la *Rectified Linear Activation Function (ReLU)*:

$$h(\mathbf{x}) = \max(0, \mathbf{x}) \tag{3.6}$$

I vantaggi della *ReLU* sono la semplicità computazionale e la capacità di avere in output il valore zero, non possibile con altre funzioni come la *sigmoid*, la quale è diversa da zero per qualsiasi valore di input. Senza l'introduzione di una componente non lineare inoltre, una rete neurale MLP perderebbe la capacità di apprendere relazioni complesse tra i dati. Poiché la composizione di trasformazioni lineari è essa stessa una trasformazione lineare, la rete risulterebbe equivalente a un modello di regressione lineare, permettendo di approssimare in modo corretto solo le funzioni lineari.

La struttura di un modello MLP è data da un livello di input, definito dai descrittori di un dato, un numero variabile di livelli nascosti dove ogni neurone esegue le operazioni descritte precedentemente, e un livello di output che determina il risultato finale della

rete neurale. Il processo dove i dati di input vengono trasformati da ciascun livello per generare un output è detto *propagazione in avanti*.

Considerando una rete neurale composta da n_1 descrittori e n_j neuroni associati ad uno strato j-esimo, è possibile scrivere una forma vettoriale delle operazioni definendo le seguenti quantità:

$$\mathbf{a}^{(1)} = \begin{pmatrix} x_0 = 1 \\ x_1 \\ \vdots \\ x_{n_1} \end{pmatrix} \quad \mathbf{a}^{(j\neq 1)} = \begin{pmatrix} a_0^{(j)} = 1 \\ a_1^{(j)} \\ \vdots \\ a_{n_j}^{(j)} \end{pmatrix} \mathbf{W}^{(j)} \quad = \begin{pmatrix} w_{10}^{(j)} & w_{11}^{(j)} & \cdots & w_{1m_j}^{(j)} \\ w_{20}^{(j)} & w_{21}^{(j)} & \cdots & w_{2m_j}^{(j)} \\ \vdots & \vdots & \ddots & \vdots \\ w_{n_j0}^{(j)} & w_{n_j1}^{(j)} & \cdots & w_{n_jm_j}^{(j)} \end{pmatrix},$$

dove la matrice $\mathbf{W}^{(j)}$ rappresenta l'insieme di tutti i parametri, ovvero pesi e bias, associati allo strato j-esimo e l'indice m_j indica il numero di input del singolo neurone, $\mathbf{a}^{(j)}$ rappresenta il vettore contente l'output di tutti i neuroni di un livello j-esimo e i $\{x_i\}_{i=1}^{n_1}$ rappresentano i descrittori dei dati di input.
L'output di un livello è quindi scrivibile nella forma compatta:

$$\mathbf{a}^{(j+1)} = h(\mathbf{W}^{(j)}\mathbf{a}^{(j)}). \tag{3.7}$$

L'applicazione di $h(\mathbf{x})$ ad un generico vettore $\mathbf{x}$ è intesa come l'applicazione della funzione alle singole componenti, ovvero $h(\mathbf{x}) = (h(x_1), h(x_2), ..., h(x_n))$.

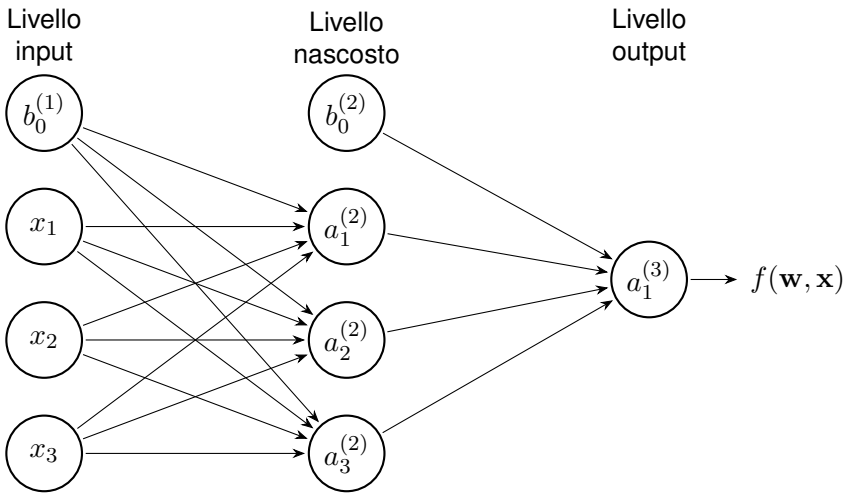


Figura 3.3: Rappresentazione grafica di un *Multilayer Perceptron* composto da tre descrittori in input $\mathbf{x} = (x_1, x_2, x_3)$, tre neuroni nello strato nascosto $\mathbf{a}^{(2)} = (a_1^{(2)}, a_2^{(2)}, a_3^{(2)})$ e un neurone di output $a_1^{(3)}$. I valori di bias $\mathbf{b} = (b_0^{(1)}, b_0^{(2)})$, sono fissati a 1.

L'ottimizzazione dei pesi di un modello MLP utilizza un processo detto *retropropagazione*, un algoritmo efficiente per il calcolo del gradiente rispetto a ciascun parametro della funzione di costo, necessario nell'algoritmo di discesa del gradiente utilizzato nell'apprendimento. La funzione di costo utilizzata è la MSE (*Mean Square Error*) definita come:

$$L(\mathbf{W}) = \frac{1}{N}\sum_{k=1}^{N}\left(f(\mathbf{W}, \mathbf{x}_k) - y_k\right)^2, \tag{3.8}$$

dove y_k è l'etichetta associta all'input $\mathbf{x}_k$, $\mathbf{W}$ è l'insieme di tutti i parametri inizialmente casuali e N è il numero di dati di allenamento. L'algoritmo di retropropagazione applica inizialmente la propagazione in avanti per calcolare il valore di output della rete neurale $f(\mathbf{W}, \mathbf{x}_k)$ e ne calcola la funzione di costo. L'attivazione dei neuroni di output dipende dai contributi dei parametri e delle attivazioni dei livelli precedenti. Le derivate parziali sono quindi calcolate ad ogni livello utilizzando la regola della catena fino a raggiungere il livello di input, da qui il nome retropropagazione. Infine si applica l'algoritmo stoscastico di discesa del gradiente per ottimizzare i parametri.

L'architettura descritta finora è detta completamente connessa poiché tutti i neuroni di un livello sono connessi a tutti i neuroni del livello successivo. Il numero di pesi necessari è generalmente proporzionale al quadrato del numero dei descrittori, rendendo il modello poco scalabile. Spesso inoltre descrittori vicini tra loro sono altamente correlati. Un'evoluzione delle reti completamente connesse sono le reti neurali convoluzionali (CNN) utilizzate spesso nell'analisi di immagini.

3.3.2 Rete neurali convoluzionali

Le CNN sono modelli invarianti per traslazione che rispettano la località dei dati. Aggiungono ad una rete neurale completamente connessa diversi livelli convoluzionali e di *pooling*:

- **Livello di convoluzione**

  Effettua l'estrazione delle caratteristiche spaziali applicando un insieme di filtri con valori determinati durante l'apprendimento, detti *kernel*. Il numero di filtri utilizzato determina il numero di canali di input del livello successivo. Matematicamente, il *kernel* opera come una finestra a scorrimento sull'intero volume di input. In ogni posizione, il livello esegue un prodotto elemento per elemento tra i pesi del filtro e la porzione di input coperta, sommandone poi i risultati.

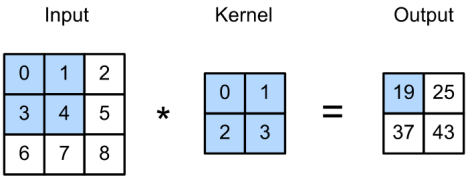


Figura 3.4: Operazione di convoluzione. Immagine tratta da [24].

- **Livello di pooling** Riduce la dimensionalità dell'input applicando una finestra a scorrimento con valori predefiniti. Le operazioni più utilizzate sono *Average Pooling* e *Max Pooling*, dove rispettivamente si calcola la media o il valore massimo dei valori dell'input compresi nella dimensione della finestra.

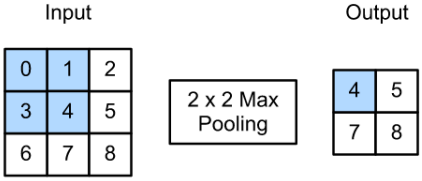


Figura 3.5: Operazione di max pooling. Immagine tratta da [24].

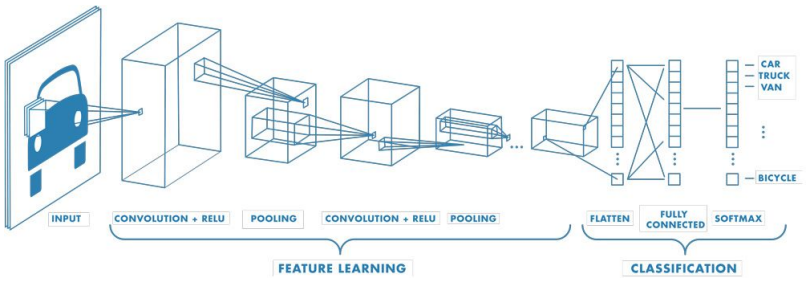


Figura 3.6: Struttura esempio di una rete neurale convoluzionale. Immagine tratta da [25]

Gli iperparametri da configurare in questi livelli sono il numero e la dimensione dei filtri, l'ampiezza del passo della finestra (*stride*) ed il numero di valori aggiuntivi ai bordi dell'input (*padding*).

A differenza di una rete neurale completamente connessa, i neuroni di un livello successivo non sono collegati a tutti quelli del livello precedente, ma ad un sottoinsieme determinato dalla dimensione dei filtri utilizzati.

L'insieme dei livelli di convoluzione e pooling restituiscono come output un tensore la cui dimensione dipende dagli iperparametri scelti. Questa sezione è poi collegata ad una rete neurale completamente connessa attraverso un livello di *flattening* che trasforma il tensore multidimensionale in un vettore unidimensionale utilizzabile nella rete.

3.4 Autoencoder variazionali

Gli autoencoder variazionali (VAE) sono modelli generativi utilizzati per generare nuovi dati sotto forma di *variazioni* dei dati di input su cui vengono allenato. Sono un sottoinsieme degli autoencoder, ovvero architetture di rete neurale progettate per codificare dati di input estraendo delle variabili latenti, ovvero vettori di dimensione ridotta che contengono le informazioni più importanti dei dati, per poi decodificarli a partire dalla rappresentazione compressa. La maggior parte delle architetture di autoencoder codifica una rappresentazione discreta e fissa di variabili latenti, mentre i VAE codificano una rappresentazione continua e probabilistica nello spazio latente, definendo una mappa tra la distribuzione dei dati di addestramento $p(\mathbf{x})$, non nota, e la distribuzione delle variabili latenti $p(\mathbf{z})$.

3.4.1 Architettura

La struttura di un VAE è suddivisa in diverse sezioni, rappresentate come in figura (3.7). La prima, detta *encoder*, consiste in una rete neurale profonda dove ogni livello contiene un numero di neuroni minore di quello precedente, in modo tale da ridurre la dimensionalità. Inoltre, spesso si utilizzano livelli convoluzionali e di pooling per estrarre le informazioni più importanti e ridurre ulteriormente la dimensionalità. L'obiettivo dell'*encoder* è approssimare la distribuzione a posteriori $p(\mathbf{z}|\mathbf{x})$, ovvero la probabilità che un vettore appartenente allo spazio latente $\mathbf{z}$ sia generato da un dato $\mathbf{x}$, ottenendo la mappa diretta tra la distribuzione dei dati di addestramento $p(\mathbf{x})$ e delle variabili latenti $p(\mathbf{z})$. La seconda sezione, detta *decoder*, consiste in un'ulteriore rete neurale profonda specchiata rispetto alla rete dell'*encoder*. Ha come obiettivo quello di approssimare la distribuzione di verosimiglianza $p(\mathbf{x}|\mathbf{z})$, ovvero la probabilità di generare un dato $\mathbf{x}$ da

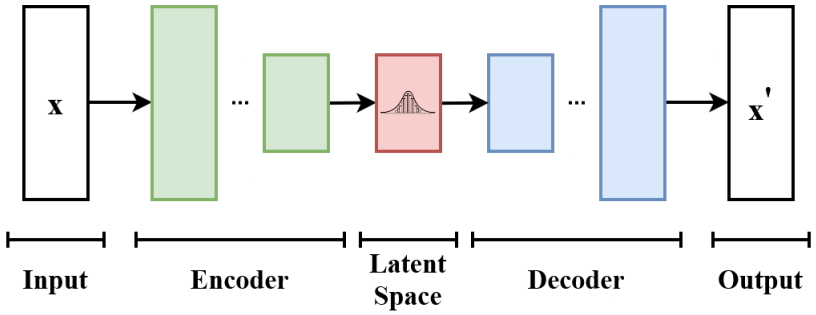


Figura 3.7: Struttura di un Autoencoder Variazionale. Immagine tratta da [26].

un vettore $\mathbf{z}$, ottenendo la mappa inversa tra le distribuzioni dei dati e variabili latenti. Questa struttura probabilistica permette di generare dati coerenti utilizzando qualsiasi valore appartenente allo spazio latente, al contrario di un autoencoder tradizionale, dove la minima variazione di una variabile latente di un dato è decodificata in un output completamente differente dall'originale. Nello specifico, il processo di inferenza di un VAE prevede che il vettore latente $\mathbf{z}$ venga campionato dalla distribuzione posteriore approssimata. Ciò garantisce che le variabili latenti occupino una regione dello spazio coerente con la distribuzione originale dei dati, permettendo al *decoder* di ricostruire campioni che preservano le caratteristiche dell'insieme di addestramento.

3.4.2 Addestramento

Le distribuzioni reali descritte nella precedente sezione non sono note; è quindi necessario introdurre delle approssimazioni. In particolare si assume che $p(\mathbf{z})$ sia una distribuzione gaussiana con media nulla e varianza unitaria $N(0, 1)$ e la distribuzione $p(\mathbf{z}|\mathbf{x})$ sia in buona approssimazione una gaussiana con media e varianza da ottimizzare $q_\phi(z|x) = N(\mu, \sigma)$. L'*encoder* è allenato per restituire come output i valori corretti di μ e σ e il *decoder* è allenato per ricostruire dati da valori campionati dalla distribuzione posteriore. La funzione di costo è composta da due termini:

$$L = (\mathbf{x} - \mathbf{x}')^2 + D_{KL}(q_\phi(\mathbf{z}|\mathbf{x}), p(\mathbf{z}|\mathbf{x})). \tag{3.9}$$

Il primo rappresenta la distanza euclidea tra il dato originale $\mathbf{x}$ e il dato ricostruito $\hat{\mathbf{x}}$, comune anche agli autoencoder tradizionali. Questo contributo è necessario per ridurre al minimo l'errore di ricostruzione dei dati, in quanto variabili latenti associate ad un dato $\mathbf{x}$ devono restituire valori ricostruiti più vicini possibile all'originale. Il secondo contributo è la *divergenza di Kullback-Leibler (KL)* e descrive la perdita di informazione adottando la distribuzione approssimata $q_\phi(\mathbf{z}|\mathbf{x})$ invece di quella reale $p(\mathbf{z}|\mathbf{x})$. L'obiettivo è quindi minimizzare la funzione di costo per ricavare i corretti parametri che definiscono l'autoencoder. La distribuzione $p(\mathbf{z}|\mathbf{x})$ non è però trattabile, poiché dipende dal teorema di Bayes dalla distribuzione $p(\mathbf{x})$. Si definisce quindi un limite inferiore per $\log(p(\mathbf{x}))$ in modo tale da non trattare direttamente $p(\mathbf{x})$:

$$\log(p(\mathbf{x})) \geq E_{q_\phi(\mathbf{z}|\mathbf{x})}[\log(p(\mathbf{x}|\mathbf{z}))] - D_{KL}(q_\phi(\mathbf{z}|\mathbf{x})|p(\mathbf{z})), \tag{3.10}$$

dove il terminte a destra è detto *Evidence Lower Bound (ELBO)*. Definendo $p(\mathbf{x}|\mathbf{z})$ come una distribuzione Gaussiana con media $f(\mathbf{z})$ e varianza proporzionale all'identità, il primo termine dell'ELBO diviene la distanza euclidea tra dato originale e ricostruito, mentre il secondo termine è la divergenza KL tra una Gaussiana dipendente da un insieme di parametri ϕ e una distribuzione normale. Utilizzando l'ELBO come funzione di costo ed applicando un processo di ottimizzazione per massimizzarla, si ottiene il massimo valore di $\log(p(\mathbf{x}))$ è il minimo valore della divergenza KL senza conoscere la forma esatta di $p(\mathbf{x})$, riuscendo cosi a ricavare i parametri corretti per il VAE.

Il processo di ottimizzazione avviene utilizzando l'algoritmo di discesa del gradiente e la retropropagazione per il calcolo effettivo del gradiente. Il processo di campionamento delle variabili latenti alla fine dell'*encoder* non è però differenziabile, poiché non è possibile determinare la variazione di $\mathbf{z}$ rispetto ad una variazione della media μ e della varianza σ. La retroproprogazione non potrebbe quindi in principio essere applicata. La soluzione per il calcolo del gradiente è data utilizzando il *trick di riparametrizzazione*, dove la casualità del processo è introdotta non nella definizione del modello, ma come input. In particolare si campiona un valore ϵ da una distribuzione normale $N(0, 1)$ e si ricava il vettore delle variabili latenti come:

$$\mathbf{z} = f(\mu, \sigma, \epsilon) = \mu + \sigma\epsilon; \tag{3.11}$$

in questo modo il processo diventa differenziabile rispetto alla media e varianza ed è possibile applicare la retropropagazione per l'ottimizzazione dei parametri.

3.5 Applicazioni nella DFT

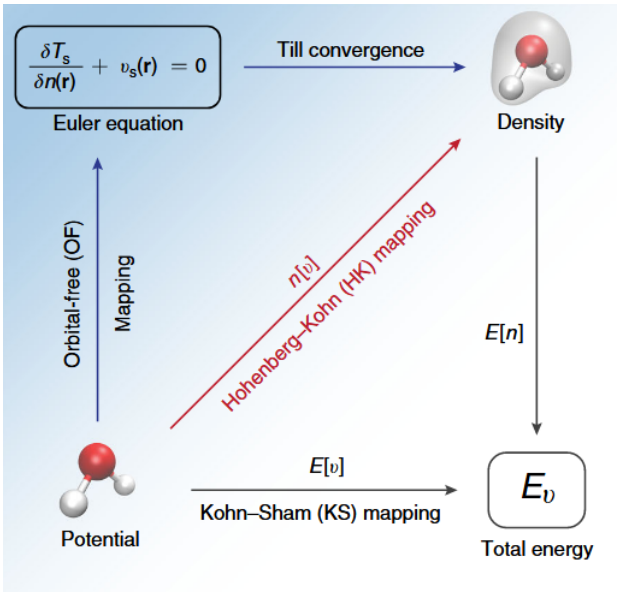


Figura 3.8: Panoramica delle possibili applicazioni dei modelli di apprendimento automatico per la teoria del funzionale della densità. Immagine tratta da [7].

Nelle seguenti sezioni sono trattate le possibili applicazioni di modelli di apprendimento automatico per la teoria del funzionale della densità. In particolare, è trattata l'approssimazione del funzionale dell'energia cinetica $T[n(\mathbf{r})]$, descritto nella sezione

(2.1), mediante l'utilizzo di una rete neurale convoluzionale e l'applicazione dell'algoritmo di discesa del gradiente per ricavare la densità dello stato fondamentale [5]. In seguito, è introdotta la possibilità di utilizzare lo spazio latente dato di un autoencoder variazionale, descritto nella sezione (3.4), per applicare il processo di minimizzazione su una rappresentazione compressa e continua delle densità.

In figura (3.8) sono mostrati i vari metodi per determinare l'energia dello stato fondamentale di un sistema. $E[V]$ rappresenta la mappa tra potenziale e energia totale, determinata mediante la risoluzione delle equazioni di Kohn-Sham, descritte in sezione (2.3.1). *Orbital-free mapping* rappresenta il metodo orbital-free DFT descritto in sezione (2.4), mentre $n[V]$ e $E[n(\mathbf{r})]$ rappresentano rispettivamente la mappa tra potenziale e densità dello stato fondamentale e tra densità e energia totale, approssimabili con l'utilizzo di modelli di apprendimento automatico.

4. Rete neurale convoluzionale per il termine cinetico

La difficoltà nella determinazione del funzionale dell'energia totale, in particolare il termine cinetico, ha indotto lo sviluppo di metodi approssimativi come Kohn-Sham e Orbital-Free DFT. In questo contesto, l'utilizzo di una rete neurale convoluzionale addestrata su sistemi in cui energia e densità dello stato fondamentale sono noti, si pone come alternativa per approssimare il termine cinetico reale [27] con l'obiettivo di ridurre la difficoltà computazionale e aumentare l'accuratezza dei risultati per sistemi con energia dello stato fondamentale non nota a priori.

4.1 Dati di addestramento

In questa sezione sono descritti gli insiemi dei dati utilizzati nell'addestramento e nella validazione delle varie architetture di CNN. Il sistema è definito in un cubo di dimensione $L = a_0$, dove a_0 è il raggio di Bohr, in cui è presente un potenziale esterno, dato dalla somma di potenziali gaussiani 3D, che soddisfa le condizione periodiche al contorno (PBC). Il potenziale in un punto $\mathbf{r}$ è calcolato come segue:

$$V(\mathbf{r}) = \frac{E_u}{N_g} \sum_{i=1}^{N_g} \frac{A_i}{(2\pi)^3/2(\sigma/a_0)^3} \exp\left[-\frac{||\mathbf{r} - \mathbf{r}_i||^2}{2\sigma^2}\right], \tag{4.1}$$

dove le componenti (x_i, y_i, z_i) dei vettori posizione $\mathbf{r_i}$ relativi a ciascuna Gaussiana sono campionate da una distribuzione uniforme nell'intervallo $[0, L]$, i fattori moltiplicativi A_i sono anch'essi campionati da una distribuzione uniforme in un intervallo $[0, 2]$ mentre la deviazione standard σ, comune a tutte le gaussiane, è fissata a $a_0/6$. N_g è il numero delle distribuzioni gaussiane utilizzate, in questo caso fissato a 10, e $E_u = \frac{\hbar^2}{2m_e a_0^2}$ è una costante che determina l'unità di misura dell'energia, ovvero Rydberg. Nel seguito, verrà assunta quest'ultima come unità di misura dell'energia.

Un insieme di dati di addestramento comprende N_i istanze, ognuna delle quali contiene:

- **Potenziale**: il potenziale definito nell'eq. (4.1) è discretizzato in $N = 18$ punti per dimensione, determinando una griglia di dimensione $18 \times 18 \times 18$. La scelta del numero di punti è tale da ridurre al minimo l'errore introdotto dalla discretizzazione nel calcolo dell'energia e massimizzare l'efficienza computazionale.
- **Energia dello stato fondamentale**: la risoluzione dell'equazione (2.5) permette di ricavare autofunzioni $\psi(\mathbf{r})$ e energie del sistema in esame. L'equazione agli autovalori è risolta numericamente utilizzando il metodo delle differenze finite a

11 punti per il Laplaciano in 3 dimensioni e un algoritmo di diagonalizzazione per la matrice Hamiltoniana sparsa.

- **Densità elettronica dello stato fondamentale**: il modulo quadro delle autofunzioni $\psi(\mathbf{r})$ ricavate precedentemente determinano la densità elettronica dello stato fondamentale $n_0(\mathbf{r})$.

- **Energia potenziale**: la natura discreta della densità elettronica e del potenziale permette di calcolare l'energia potenziale come segue:

$$V_E = \sum_{i=1}^{N^3} n_0(\mathbf{r}_i) V(\mathbf{r}_i) \Delta x^3 \tag{4.2}$$

dove $\Delta x^3 = \left(\frac{L}{N}\right)^3$ è il volume della cella elementare e r_i indicano i punti della griglia.

4.1.1 Sistema di singolo elettrone

Il primo sistema trattato è quello di singolo elettrone confinato all'interno del cubo descritto precedentemente. In questo scenario, l'energia dello stato fondamentale coincide con il più piccolo autovalore della matrice Hamiltoniana e la densità è il modulo quadro dell'autofunzione relativa all'autovalore trovato.

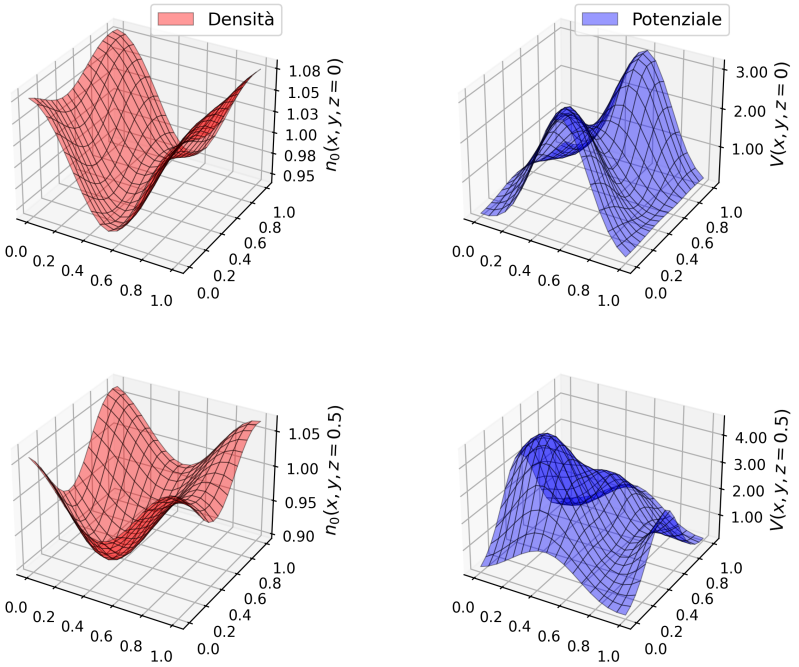


Figura 4.1: Esempio illustrativo di sezioni di una densità dello stato fondamentale $n_0(x, y, z)$ (superfici in rosso) e sezioni del relativo potenziale $V(x, y, z)$ (superfici in blu). L'energia è espressa in Rydberg e l'asse x e y sono relativi al raggio di Bohr a_0.

L'insieme di addestramento contiene $N_i = 100000$ istanze. In figura (4.1) sono presentate sezioni di una densità e del potenziale associato. La densità assume valori vicini ad 1, con variazione regolare. Inoltre, ai picchi del potenziale corrispondono i minimi della densità. Nelle seguenti figure sono riportate le distribuzioni dell'energia dello stato fondamentale (figura 4.2), dell'energia potenziale (figura 4.3) e cinetica (figura 4.4). Quest'ultima è ricavata dall'insieme dei dati sottraendo l'energia potenziale all'energia totale.

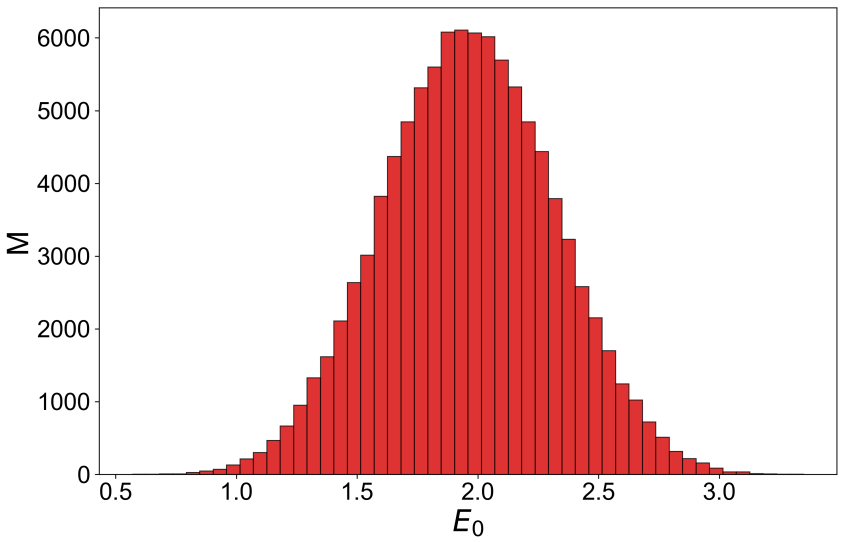


Figura 4.2: Distribuzione dell'energia dello stato fondamentale E_0 al variare dei parametri del potenziale. L'energia è espressa in Rydberg e M rappresenta il numero di elementi.

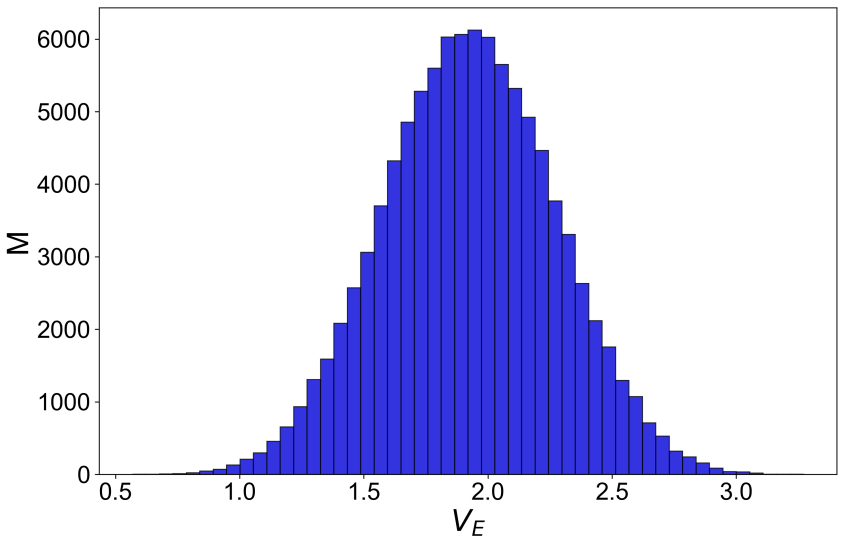


Figura 4.3: Distribuzione dell'energia potenziale totale V_E al variare dei parametri del potenziale. L'energia è espressa in Rydberg e M rappresenta il numero di elementi.

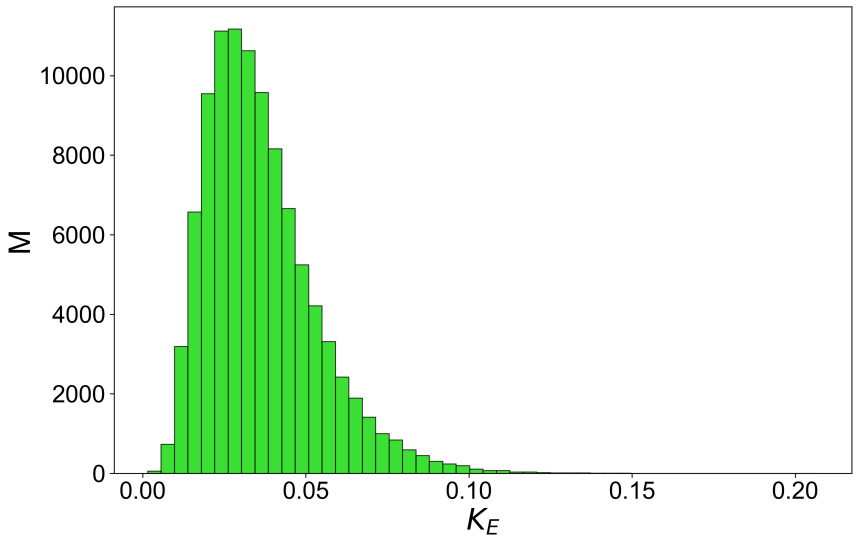


Figura 4.4: Distribuzione dell'energia cinetica K_E al variare dei parametri del potenziale. L'energia è espressa in Rydberg e M rappresenta il numero di elementi.

I grafici mostrano come l'energia totale abbia una distribuzione simile ad una Gaussiana centrata a 2 Rydberg, con code che vanno da 0.5 a 3 Rydberg. Inoltre, il contributo dell'energia potenziale è molto maggiore di quello cinetico. La distribuzione di quest'ultima differisce da una Gaussiana, con picco a 0.03 Rydber e valori che vanno da 0 a 0.15 Rydberg.

4.1.2 Sistema di 20 elettroni non interagenti

Il secondo sistema trattato è costituito da 20 elettroni non interagenti, di cui 10 spin-up e 10 spin-down, nelle stesse condizioni del sistema precedente. L'energia dello stato fondamentale è data dalla somma dei 10 livelli energetici moltiplicati per la degenerazione dello spin, ovvero:

$$E_0 = 2\sum_{i=0}^{9} e_i, \tag{4.3}$$

dove e_i rappresenta l'energia del singolo livello energetico. La densità dello stato fondamentale è data dalla somma dei moduli quadri delle funzione d'onda di singola particella moltiplicati per la degenerazione dello spin, cioè:

$$n(\mathbf{r}) = 2\sum_{i=0}^{9} |\psi_i(\mathbf{r})|^2. \tag{4.4}$$

I seguenti grafici illustrano le proprietà dei dati nell'insieme di addestramento contenente $N_i = 300000$ istanze. La figura (4.5) mostra un esempio di densità dello stato fondamentale associata ad un potenziale. Le figure (4.6), (4.7) e (4.8) mostrano rispettivamente la distribuzione dell'energia dello stato fondamentale, potenziale e cinetica.

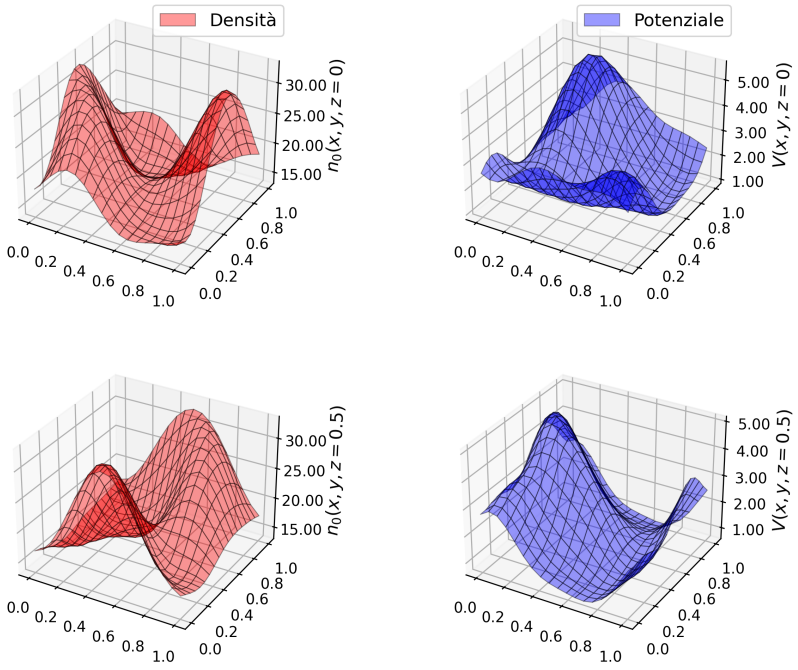


Figura 4.5: Esempio illustrativo di sezioni di una densità dello stato fondamentale $n_0(x, y, z)$ (superfici in rosso) e sezioni del relativo potenziale $V(x, y, z)$ (superfici in blu). L'energia è espressa in Rydberg e l'asse x e y sono relativi al raggio di Bohr a_0.

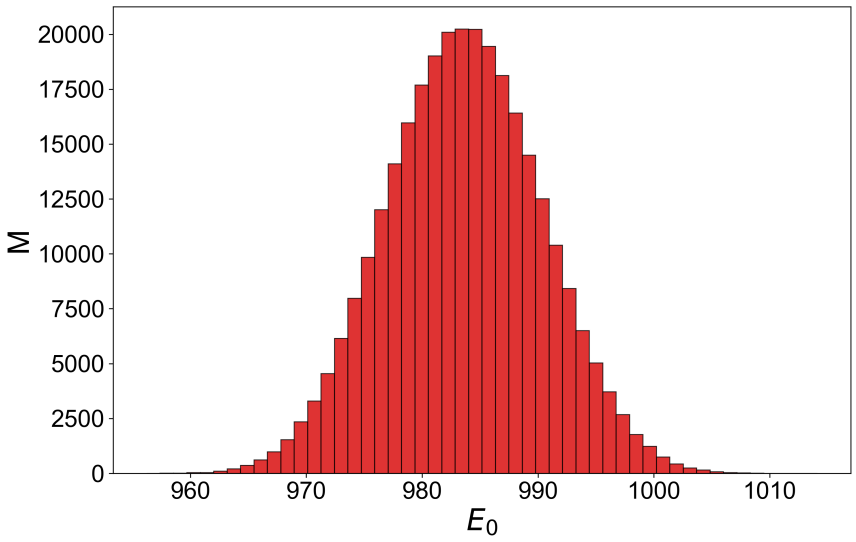


Figura 4.6: Distribuzione dell'energia dello stato fondamentale E_0 al variare dei parametri del potenziale. L'energia è espressa in Rydberg e M rappresenta il numero di elementi.

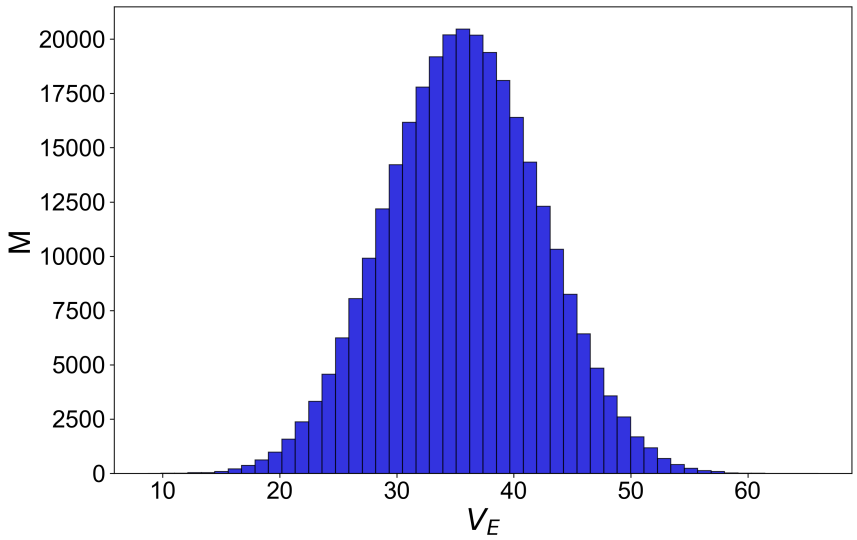


Figura 4.7: Distribuzione dell'energia potenziale totale V_E al variare dei parametri del potenziale. L'energia è espressa in Rydberg e M rappresenta il numero di elementi.

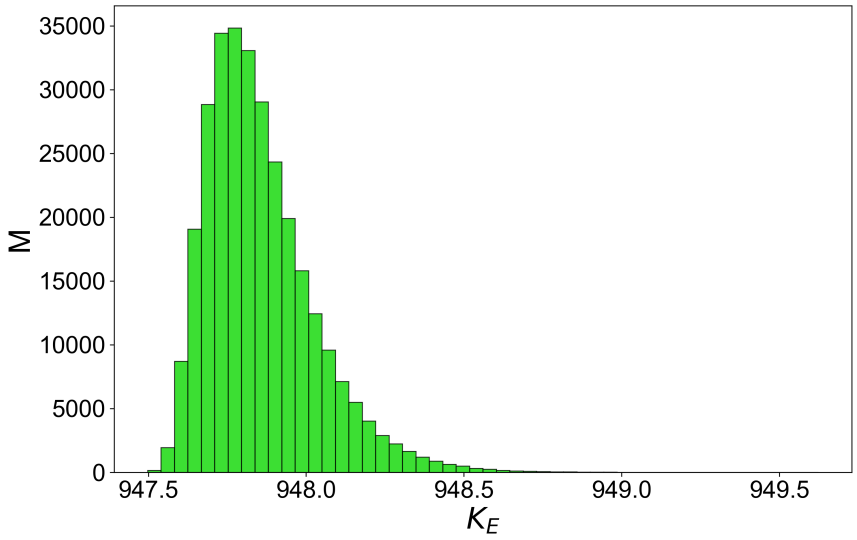


Figura 4.8: Distribuzione dell'energia cinetica K_E al variare dei parametri del potenziale. L'energia è espressa in Rydberg e M rappresenta il numero di elementi.

La densità dello stato fondamentale mostra valori maggiori rispetto al sistema precedente e un andamento più variabile, dovuto alla presenza di un numero maggiore di fermioni. Le distribuzioni delle energie hanno un andamento simile a quello precedente, ma presentano valori più elevati. Inoltre, in questo caso l'energia cinetica è molto maggiore di quella potenziale.

4.1.3 Sistema di 10 elettroni non interagenti

L'ultimo sistema trattato è quello di 10 elettroni non interagenti, di cui 5 spin-up e 5 spin-down, nelle stesse condizioni dei sistemi trattati finora. Rispetto ai casi precedenti però, l'energia totale, l'energia potenziale e cinetica del sistema è qui scomposta nei contributi individuali dei primi cinque stati energetici occupati. I seguenti grafici sono relativi a $N_i = 100000$ istanze.

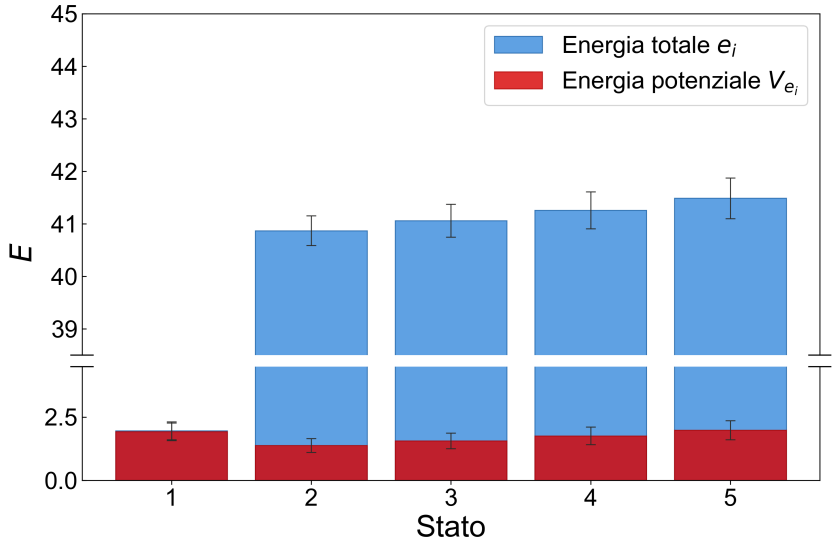


Figura 4.9: Valore medio e deviazione standard dell'energia totale e potenziale per stato i-esimo. e_i e V_{e_i} rappresentano rispettivamente l'energia totale e potenziale per stato, espresse in Rydberg.

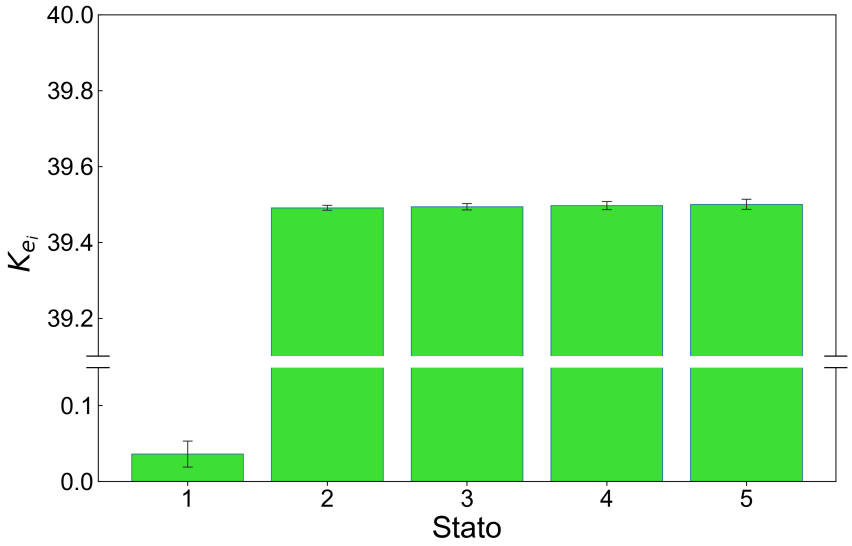


Figura 4.10: Valore medio e deviazione standard dell'energia cinetica per stato i-esimo. K_{e_i} rappresenta il valore dell'energia cinetica per stato, espressa in Rydberg.

La figura (4.9) mostra l'andamento dell'energia totale e potenziale per i primi 5 livelli energetici del sistema. Il dato più evidente è la differenza di energia totale tra il primo livello ed i restanti, con la differenza tra primo e secondo di $\Delta K_E = 38.90$ Rydberg. Da $n = 2$ in poi la crescita è lenta e lineare, con un incremento di circa 0.6 Rydberg per livello. L'energia potenziale invece presenta valori vicini tra loro, con il massimo per $n = 1$. La differenza tra energia totale e potenziale permette di ricavare l'energia cinetica per stato, mostrata in figura (4.10). La differenza qui tra il primo livello e i restanti è di poco maggiore rispetto a quella dell'energia totale, con $\Delta K_E = 39.45$ Rydberg. Da $n = 2$ in poi, l'energia cinetica rimane quasi costante a $K_E = 39.49$ Rydberg. Inoltre, la piccola deviazione standard dei livelli con n maggiore di 2 dimostra che il potenziale definito precedentemente con parametri diversi danno luogo alla medesima energia cinetica per stati eccitati.

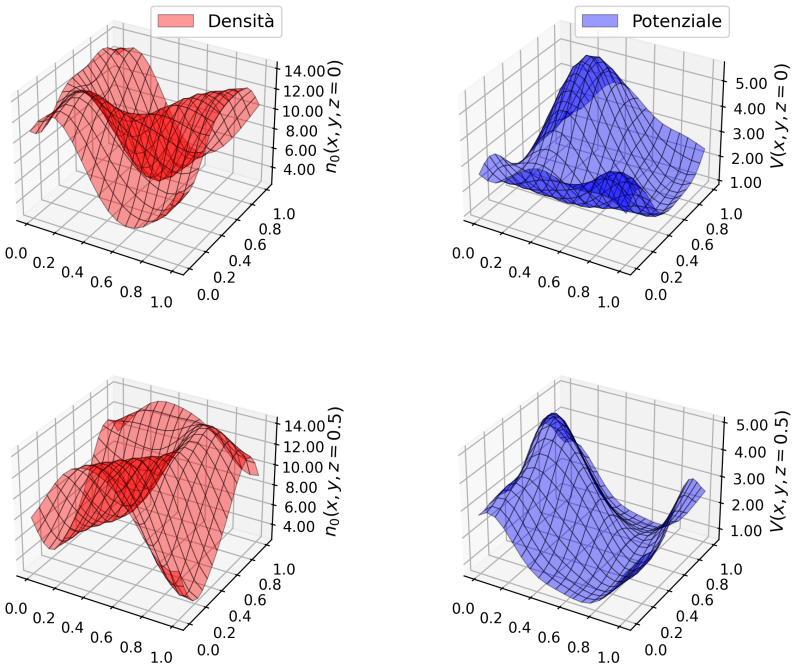


Figura 4.11: Esempio illustrativo di sezioni di una densità dello stato fondamentale $n_0(x, y, z)$ (superfici in rosso) e sezioni del relativo potenziale $V(x, y, z)$ (superfici in blu). L'energia è espressa in Rydberg e l'asse x e y sono relativi al raggio di Bohr a_0.

Dalle relazioni (4.3) e (4.4), con la sommatoria modificata per considerare i primi 5 stati, è possibile ricavare energia dello stato fondamentale, potenziale, cinetica e la densità elettronica del sistema totale. La figura (4.11) mostra un esempio di densità associata ad una delle possibili configurazioni del potenziale. Come nel caso di 20 elettroni, la densità è maggiore e molto più variabile rispetto al caso di singolo elettrone, dovuto alla presenza di un numero maggiore di elettroni. Le figure (4.12), (4.13), (4.14) mostrano rispettivamente la distribuzione dell'energia dello stato fondamentale, potenziale e cinetica del sistema su $N_i = 100000$ istanze. L'andamento è simile ai casi precedenti, con valori minori del caso a 20 elettroni dovuto al minor numero di

particelle presenti. Confrontando quest'ultimi grafici con quelli relativi alle energie di singolo stato, è chiaro come l'energia cinetica totale dipenda sostanzialmente solo dal primo livello energetico, essendo i restanti quasi costanti.

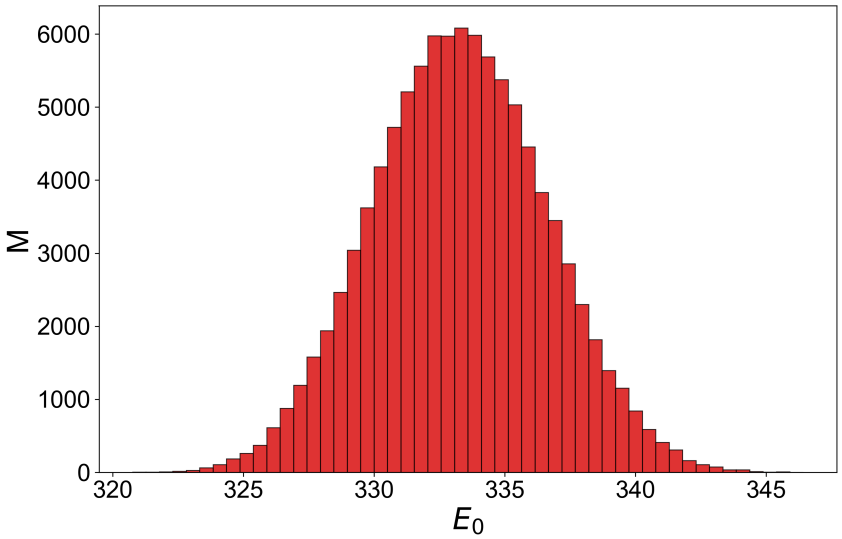


Figura 4.12: Distribuzione dell'energia dello stato fondamentale E_0 al variare dei parametri del potenziale. L'energia è espressa in Rydberg e M rappresenta il numero di elementi.

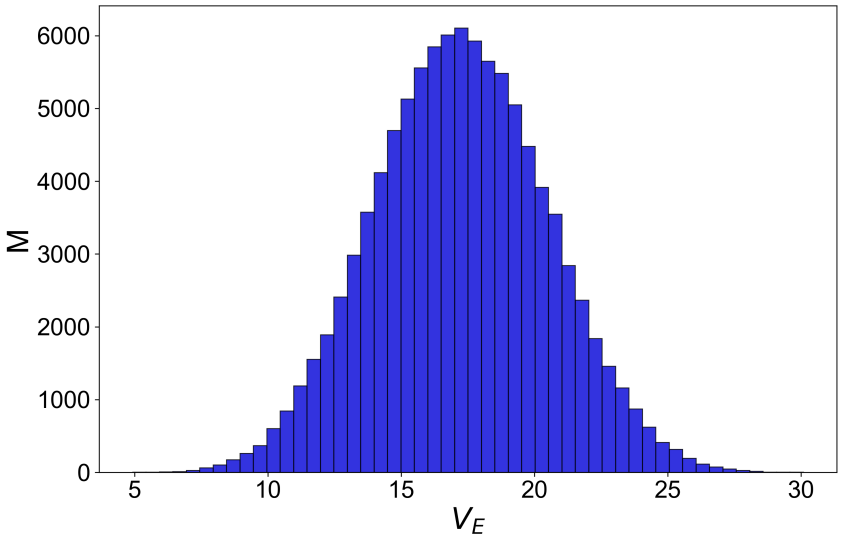


Figura 4.13: Distribuzione dell'energia potenziale totale V_E al variare dei parametri del potenziale. L'energia è espressa in Rydberg e M rappresenta il numero di elementi.

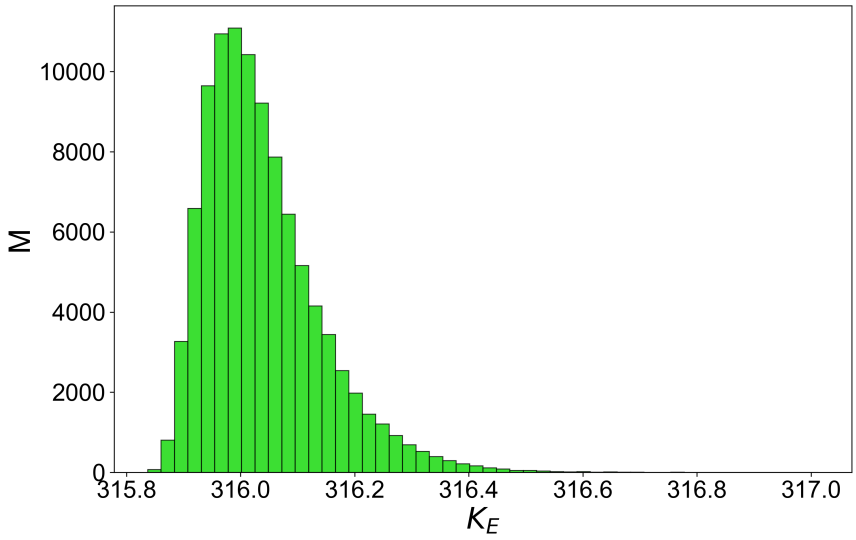


Figura 4.14: Distribuzione dell'energia cinetica K_E al variare dei parametri del potenziale. L'energia è espressa in Rydberg e M rappresenta il numero di elementi.

4.2 Analisi architetture e risultati

La scelta delle caratteristiche della CNN deve essere tale da poter apprendere al meglio la relazione tra densità dello stato fondamentale e energia cinetica, evitando i problemi di underfitting e overfitting, descritti nella sezione (3.2.2). La CNN complessiva è composta da diversi livelli convoluzionali e di pooling, connessi ad una rete completamente connessa da un livello di *flattening*. In questa sezione sono analizzate le prestazioni al variare del numero di livelli iniziali e al variare della dimensione di output dei livelli antecedenti a quelli della rete completamente connessa. In particolare, sono trattati i valori di MSE e R^2, definite nella sezione (3), sui dati di addestramento, validazione e test, relativi al sistema di singolo elettrone, di 20 elettroni e 10 elettroni, e il tempo necessario per realizzare N_e epoche d'addestramento.

4.2.1 Sistema di singolo elettrone

In questa sezione è trattato l'insieme dei dati relativi al sistema di singolo elettrone descritto nella sezione nella sezione (4.1.1). I parametri come *padding*, *stride* e *kernel size* dei livelli di convoluzione e pooling sono variati tra i vari modelli in modo tale da mantenere la dimensione e il numero di livelli della rete completamente connessa costanti, con i seguenti valori:

- Numero livelli = 6,
- Dimensione input = 480,
- Dimensione output = 1.

Per verificare come i livelli iniziali influenzino le prestazioni complessive della CNN, i seguenti iperparametri sono mantenuti costanti:

- Numero epoche $N_e = 150$,
- Tasso di apprendimento $L_r = 10^{-4}$,
- Dimensione Batch = 64,
- Numero canali = 60.

Infine, la funzione d'attivazione utilizzata per ogni livello, tranne per quello di output, è la *Softplus*, definita come:

$$f(x) = \ln(1 + e^x). \tag{4.5}$$

mentre l'algoritmo di ottimizzazione utilizzato è *Adam* [28], una variante dell'algoritmo stocastico di discesa del gradiente che implementa un tasso di apprendimento dinamico, dipendete da quello scelto inizialmente chiamato tasso di apprendimento globale. Quest'ultimo determina il fattore di scala e deve essere scelto in modo tale da permettere la convergenza efficiente dell'algoritmo. In questo caso sono stati testati sul modello M1 (tabella 4.1) due tassi di apprendimento, rispettivamente $L_r = 1 \times 10^{-2}$ e $L_r = 1 \times 10^{-4}$ per 50 epoche, ottenendo i risultati in figura (4.15). I grafici (4.15a) e (4.15b), relativi al tasso di apprendimento $L_r = 1 \times 10^{-2}$, mostrano una diminuzione iniziale del MSE sia sui dati di addestramento che di validazione, per poi incrementare fino alla convergenza su MSE ≈ 0.0003. R^2 tende inizialmente ad 1, per poi convergere

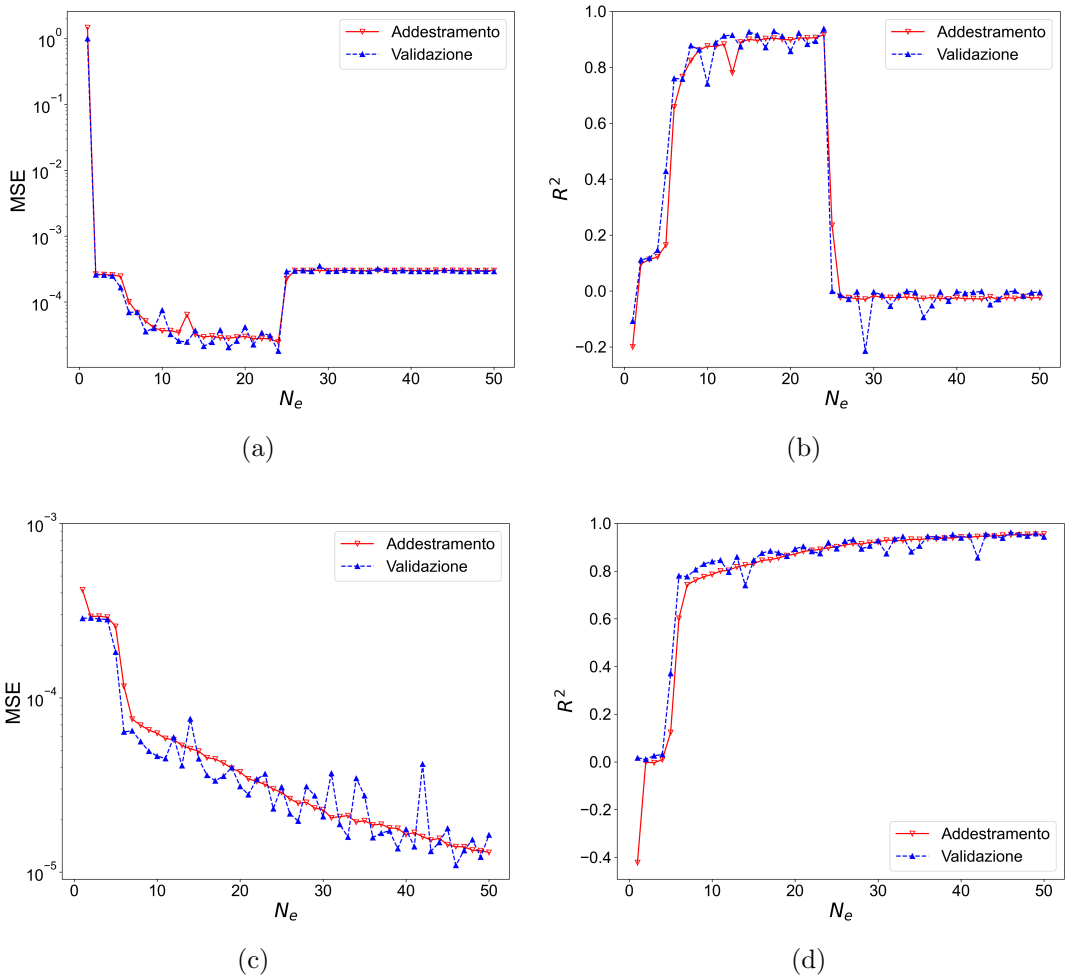


Figura 4.15: Sistema di singolo elettrone. (a) e (b) mostrano rispettivamente i valori di MSE e R^2 in funzione del numero di epoche per dati di addestramento e validazione relativi a $L_r = 10^{-2}$, mentre (c) e (d) mostrano i valori relativi a $L_r = 10^{-4}$.

a $R^2 \approx 0$. Ciò indica che l'algoritmo converge in un minimo locale della funzione di costo ed il modello dà come output, per ogni densità, il valor medio dell'energia cinetica. $L_r = 1 \times 10^{-2}$ non è quindi la scelta corretta per il tasso di apprendimento, in quanto non permette all'algoritmo di raggiungere il minimo assoluto della funzione di costo. I grafici (4.15c) e (4.15d), relativi al tasso di apprendimento $L_r = 1 \times 10^{-4}$, mostrano una diminuzione costante della funzione di costo e un R^2 tendente ad 1, ovvero il modello apprende correttamente la relazione tra densità ed energia cinetica. Quest'ultimo tasso di apprendimento è quindi la scelta migliore per raggiungere la convergenza al minimo assoluto del MSE con un costo computazionale trattabile.

Modello	$\mathbf{N_C}$	$\mathbf{N_M}$	$\mathbf{T_A}$	**MSE**	$\mathbf{R^2}$
M1	1	1	16min 7s	3.665×10^{-5}	0.8717
M2	2	2	28min 24s	2.728×10^{-6}	0.9904
M3	3	3	36min 21s	1.334×10^{-6}	0.9953
M4	4	4	45min 28s	1.116×10^{-6}	0.9960
M5	5	5	56min 25s	8.723×10^{-7}	0.9969
M6	6	6	59min 10s	2.873×10^{-4}	-0.0054

Tabella 4.1: Numero di livelli convoluzionali (N_C), numero di livelli di maxpool (N_M), tempo di addestramento (T_A), MSE e R^2 su insieme di test per tutti i modelli testati.

L'obiettivo dell'analisi dell'accuratezza e efficienza, misurate da MSE, R^2 e tempo di addestramento, di diverse architetture di CNN è identificare il modello che permetta di avere l'errore tra energia cinetica predetta e reale al di sotto della *chemical accuracy*, fissata generalmente a 3.2 Rydberg. I modelli analizzati sono mostrati nella tabella (4.1). I livelli convoluzionali e di maxpool sono aggiunti progressivamente a coppia, iniziando con il modello con complessità minore M1, il quale presenta una sola coppia di livelli, fino a M6, il quale presenta 6 coppie di livelli. I grafici in figura (4.16) mostrano l'andamento di MSE e R^2 per tutti i modelli per $N_e = 150$ epoche su l'insieme di addestramento e validazione. Il dato più evidente che emerge dai grafici è la staticità del modello M6. Aumentando la complessità da M5, il risultato aspettato è una diminuzione del MSE e aumento di R^2 su entrambi gli insiemi con conseguente incremento del tempo di addestramento. Al contrario, M6 presenta un leggero miglioramento sulle prime epoche, per poi stabilizzarsi a MSE $\approx 2.938 \times 10^{-4}$ e $R^2 \approx 0$, ovvero risultati peggiori rispetto ai precedenti modelli. Come detto precedentemente, ciò mostra che M6 non riesce ad estrarre informazioni dall'insieme di addestramento, ma converge in modo tale da dare come output il valor medio dell'energia cinetica. Per escludere il tasso di apprendimento iniziale come problema per il modello, è stato testato anche il caso $L_r = 1 \times 10^{-6}$ su di esso. Il risultato è identico a quello con $L_r = 1 \times 10^{-4}$, dimostrando che il problema è strutturale, ovvero il numero di livelli convoluzionali e di maxpool è eccessivo rispetto alla rete completamente connessa posta dopo di essi. Per tentare la convergenza va quindi modificata l'intera architettura ma, come verrà poi mostrato, ciò non è necessario poiché gli altri modelli raggiungono buoni risultati in tempi relativamente brevi. I modelli da M1 a M5 mostrano invece andamenti coerenti con le aspettative, ovvero all'aumentare della complessità aumentano tempi di addestramento e accuratezza. M1 ha un architettura troppo semplice, infatti presenta underfitting visibile dall'andamento del MSE maggiore rispetto ad altri ed R^2 minore di 0.9. I rimanenti hanno andamenti di MSE e R^2 e valori sull'insieme di test comparabili, con i risultati migliori dati da M5. Quest'ultimo ha un andamento iniziale di MSE su insieme di addestramento e validazione simile a M6, per poi decrescere rapidamente al valore più piccolo ricavato da tutti i modelli. Si ha una situazione analoga anche sull'andamento di R^2. Il miglioramento introdotto da M5 rispetto a M4 su MSE su dati di test è di circa 21%, mentre rispetto a M3 è di circa 34%. Il tempo di addestramento aumenta però rispettivamente di circa 11 e 20 minuti. M3 è il modello è più efficiente rispetto agli altri, in quanto raggiunge valori di R^2 molto vicini ad 1 e MSE vicino al valore di M5, in tempi minori. Nonostante ciò, in quanto l'incremento di tempo è tollerabile, è conveniente utilizzare il modello con MSE più piccolo in assoluto e R^2 maggiore, ovvero M5.

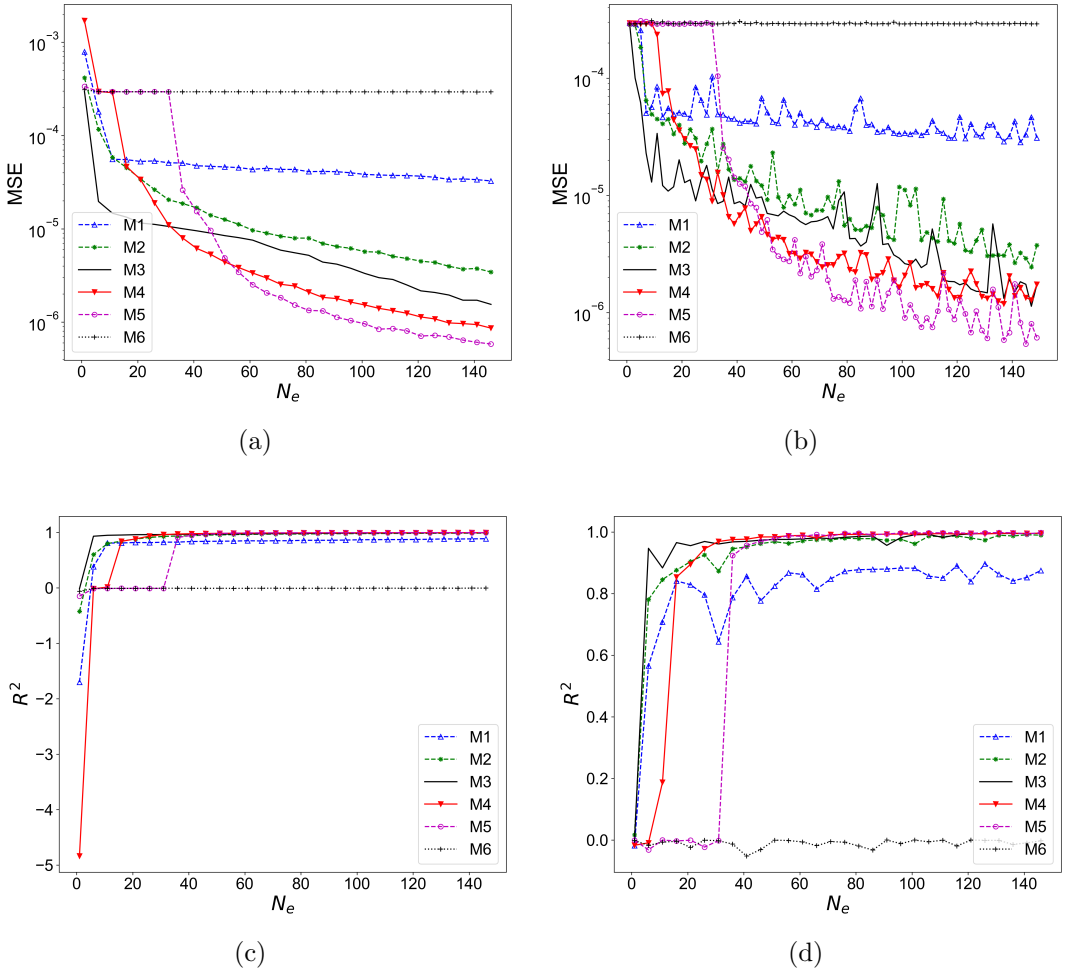


Figura 4.16: Sistema di singolo elettrone. I grafici (a) e (b) mostrano l'andamento di MSE in funzione del numero di epoche per i dati di addestramento e validazione dei vari modelli. I grafici (c) e (d) mostrano gli andamenti di R^2 per gli stessi dati.

La seguente analisi è invece incentrata sulla misura delle prestazioni al variare della dimensione dell'input della rete completamente connessa mantenendo il numero di livelli di convoluzione e maxpool uguali a quelli del modello M5. I parametri di quest'ultimi sono variati in modo tale da avere la dimensione di output coincidente con quella di input della rete seguente. In tabella (4.2) sono mostrati i valori delle dimensioni utilizzati e relative prestazioni su insieme di test. In figura (4.17) sono mostrati gli andamenti di MSE e R^2 su insieme di addestramento e validazione. Gli andamenti sono simili tra loro, mostrano maggiore discrepanza nelle epoche iniziali, per poi convergere a valori vicini all'aumentare del numero di epoche. La differenza maggiore sta nel tempo di addestramento. Utilizzando la dimensione $N_D = 60$ si diminuisce il tempo rispetto al modello M5-480, ovvero il modello M5 descritto precedentemente, di circa 19 minuti, diminuendo inoltre MSE del 32% sull'insieme di test. La scelta della dimensione $N_D = 60$ non è casuale. Poiché il numero di canali è 60, utilizzare come output la dimensione $N_D = 60$ equivale ad avere un singolo valore per canale.

Modello	$\mathbf{N_D}$	$\mathbf{T_A}$	**MSE**	$\mathbf{R^2}$
M5-60	60	37min 27s	5.883×10^{-7}	0.9979
M5-480	480	56min 25s	8.723×10^{-7}	0.9953
M5-1620	1620	1h 2min 50s	9.761×10^{-7}	0.9965

Tabella 4.2: Sistema di singolo elettrone. Dimensione di input della rete completamente connessa (N_D), tempo di addestramento (T_A), MSE e R^2 su insieme di test per tutti i modelli testati.

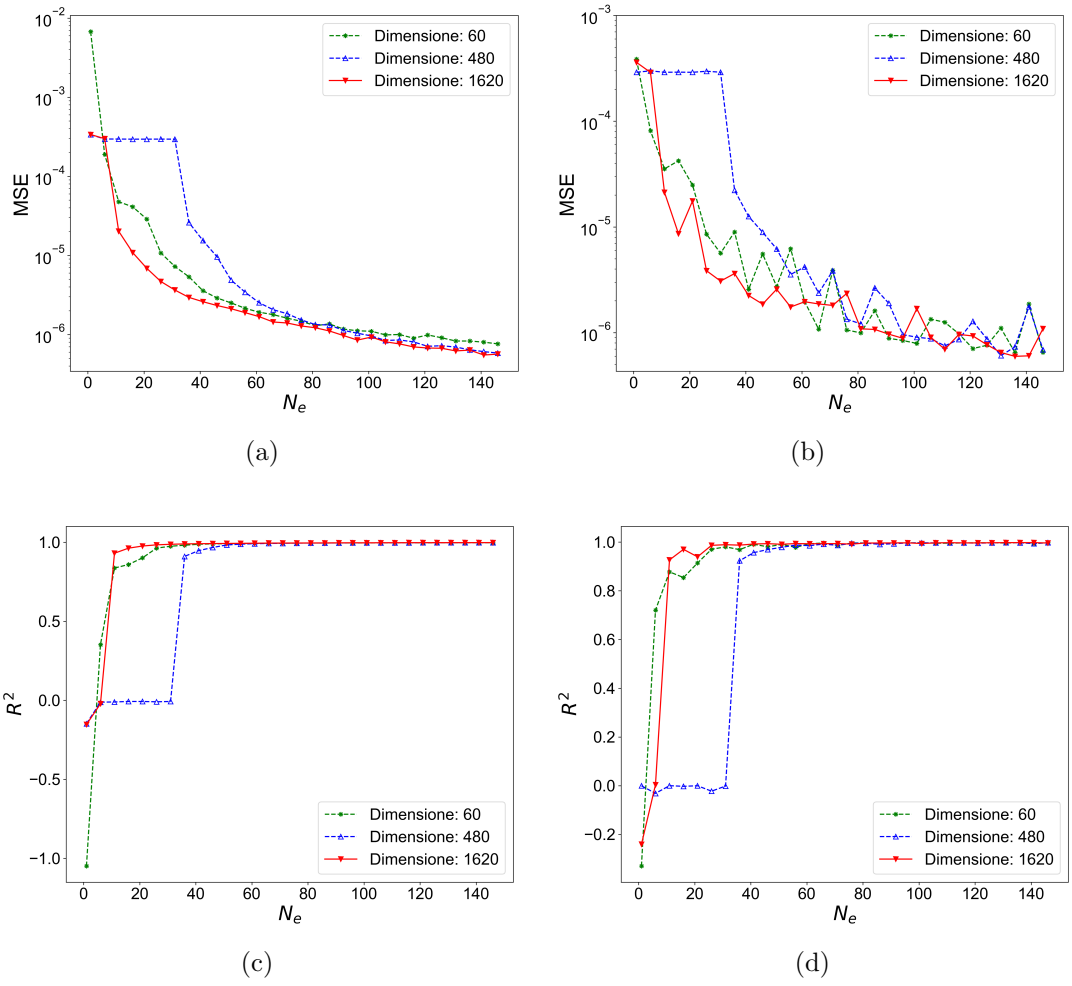
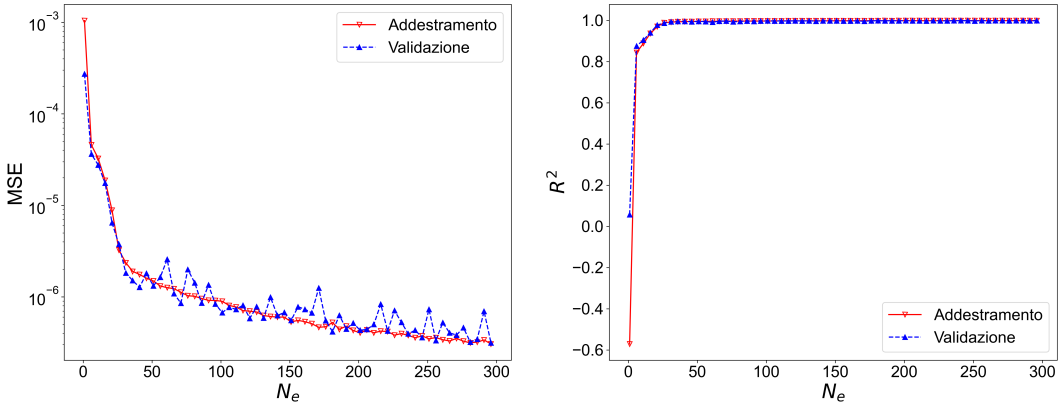


Figura 4.17: Sistema di singolo elettrone. I grafici (a) e (b) mostrano l'andamento di MSE in funzione del numero di epoche per i dati di addestramento e validazione dei vari modelli. I grafici (c) e (d) mostrano gli andamenti di R^2 per gli stessi dati.

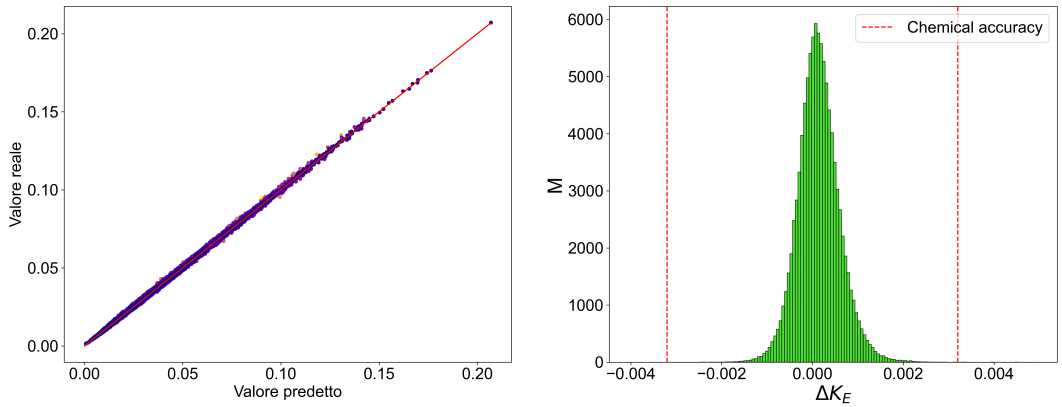
Il modello M5-1620 invece peggiora in tutte le circostanze, aumentando il tempo di addestramento di 5 minuti e MSE del 12%. La scelta migliore è quindi un architettura formata 5 livelli convoluzionali e 5 maxpool, con dimensione di input della rete completamente connessa, formata da 6 livelli, di $N_D = 60$. In questo modo, è possibile avere il minor MSE e R^2 molto vicino ad 1, con un tempo di addestramento relativamente

basso. Quest'ultimo modello è stato poi allenato per $N_e = 300$ epoche per raggiungere la convergenza e aumentare le prestazioni, ottenendo i risultati posti in seguito.



(a) (b)

Figura 4.18: Modello M5-60 su sistema di singolo elettrone. Il grafico (a) mostra l'andamento di MSE su dati di addestramento e validazione, mentre il grafico (b) mostra l'andamento di R^2 su i stessi dati



(a) (b)

Figura 4.19: Modello M5-60 su sistema di singolo elettrone. Il grafico (a) mette in relazione i valori predetti dal modello con quelli reali. La precisione del modello è visualizzata tramite la vicinanza dei punti alla retta ideale: il colore blu indica errori minimi, mentre il passaggio verso il rosso segnala un aumento della differenza tra la predizione e il valore effettivo. Il grafico (b) mostra la distribuzione degli errori, definiti come $\Delta K_E = K_p - K$, dove K_p è il valore predetto e K il valore reale.

La figura (4.18) mostra l'andamento asintotico verso MSE $\approx 2 \times 10^{-7}$ e $R^2 \approx 1$, ovvero il modello è perfettamente in grado di apprendere la relazione tra densità dello stato fondamentale e energia cinetica. Ciò è confermato anche dalla figura (4.19), nella quale è mostrato che la maggior parte delle predizioni ha una discrepanza dal valore reale compresa tra ± 0.002 Rydberg, ben al di sotto della *chemical accuracy*. Si hanno risultati analoghi anche sull'insieme di test, dimostrando la capacità del modello

Modello	$\mathbf{T_A}$	**MSE**	$\mathbf{R^2}$
M5-60	1h 13min 26s	3.287×10^{-7}	0.9988

Tabella 4.3: Modello M5-60 su sistema di singolo elettrone. Tempo di addestramento (T_A), MSE e R^2 su insieme di test per il modello M5-60 con $N_e = 300$.

di generalizzare a densità non utilizzate durante l'addestramento, escludendo quindi fenomeni di overfitting. Il tempo di addestramento è relativamente basso, ciò permette di addestrare il modello su ulteriori insiemi di dati in poco tempo.

L'analisi realizzata dimostra come aggiungendo livelli di convoluzione e maxpool aumenti l'accuratezza, determinata dalla diminuzione del MSE e aumento di R^2, e tempo di addestramento. Si raggiunge un limite con 6 coppie di livelli, dove la rete non riesce più ad apprendere correttamente, ma converge ad un modello con output costante. Infine, variando la dimensione di input della rete completamente connessa non incide molto sull'accuratezza, ma varia il tempo di addestramento. Utilizzando la dimensione minima, ovvero 60, è possibile avere la massima accuratezza con il minimo tempo di addestramento.

4.2.2 Sistema di 20 elettroni non interagenti

L'elevata accuratezza raggiunta dal modello M5-60 sul sistema di singolo elettrone porta a ritenere possibile addestrare lo stesso modello su un sistema più complesso, ovvero quello di 20 elettroni non interagenti. Il processo di addestramento è analogo al sistema di singolo elettrone. In questo caso, utilizzando l'insieme di addestramento con valori di energia cinetica e densità reali, la rete non converge a valori di MSE e R^2 accettabili, ottenendo nell'insieme di test i risultati posti in tabella (4.4).

Modello	$\mathbf{T_A}$	**MSE**	$\mathbf{R^2}$
M5-60	3h 38min 43s	0.9725	-31.92

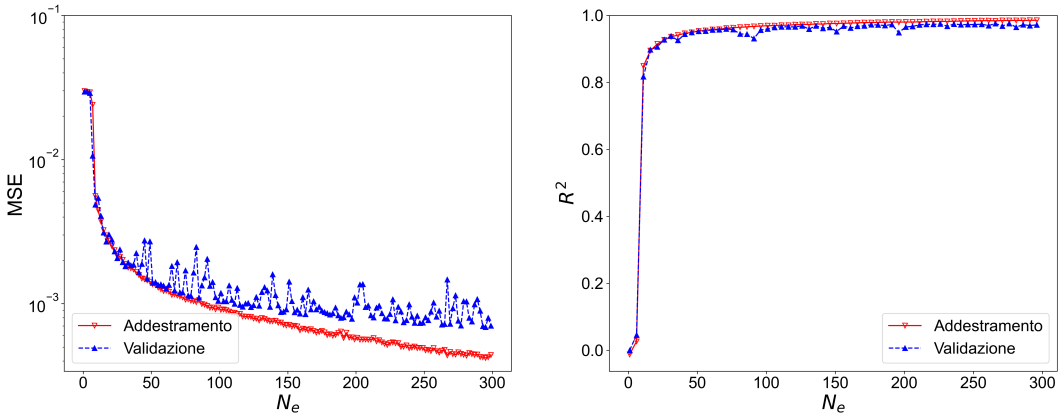
Tabella 4.4: Modello M5-60 su sistema di 20 elettroni non interagenti con insieme di addestramento non standardizzato. Tempo di addestramento (T_A), MSE in Rydberg^2 e R^2 su insieme di test con $N_e = 300$.

La rete con dati non scalati ha un accuratezza peggiore di un modello che ha come output il valor medio dell'energia cinetica per ogni densità data in input. È necessario quindi introdurre la standardizzazione delle densità e dell'energia cinetica appartenenti all'insieme di addestramento, validazione e test, definita come:

$$\mathbf{Z}_i = \frac{\mathbf{X}_i - \mu}{\sigma} \tag{4.6}$$

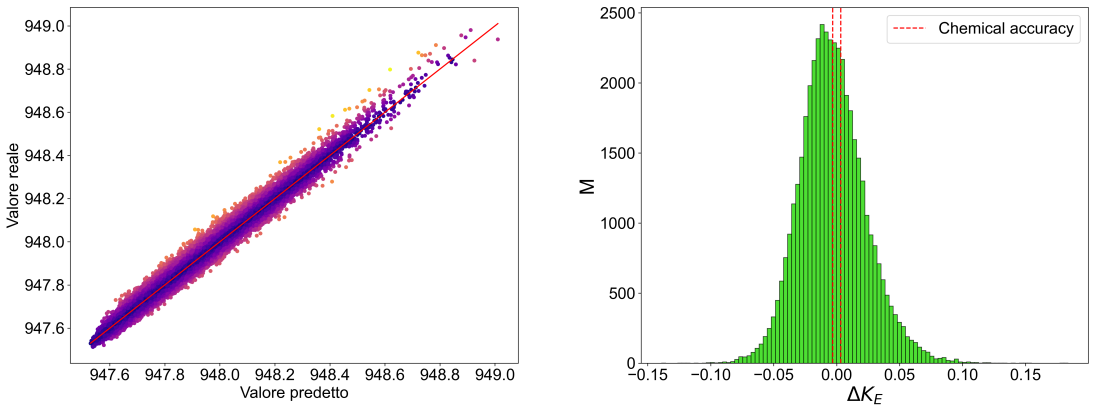
dove $\mathbf{X}_i$ è l'insieme da standardizzare, μ e σ sono rispettivamente il valor medio e deviazione standard dell'insieme di addestramento. Quest'ultimi non sono calcolati sull'intero insieme di dati per evitare il *data leakage*, ovvero aggiungere informazioni durante addestramento, validazione e test, non disponibili quando il modello è utilizzato per fare predizioni su dati al di fuori dell'insieme iniziale. In questo modo, si ottengono risultati migliori rispetto al caso non standardizzato. La tabella (4.5) mostra MSE su insieme di test estremamente ridotto e R^2 migliore rispetto al caso con dati non

standardizzati. Nonostante ciò, il modello presenta diversi problemi. In particolare, dai grafici in figura (4.20) si nota come il valore di MSE su dati di validazione oscilli in un intorno di 1×10^{-3}, mentre MSE sui dati di addestramento diminuisca in modo regolare. Per R^2, il valore sui dati di addestramento è leggermente maggiore rispetto al valore sui dati di validazione. Ciò mostra che il modello presenta overfitting, realizzando predizioni molto accurate sui dati dell'insieme di addestramento, non riuscendo però a generalizzare con la stessa accuratezza a nuovi dati. L'errore introdotto dal modello è mostrato nei grafici in figura (4.21). Solo il 10.1% delle previsioni rientra nell'intervallo della *chemical accuracy*.



(a) (b)

Figura 4.20: Modello M5-60 su sistema di 20 elettroni non interagenti con insieme standardizzato. Il grafico (a) mostra l'andamento di MSE su dati di addestramento e validazione, mentre il grafico (b) mostra l'andamento di R^2 su i stessi dati



(a) (b)

Figura 4.21: Modello M5-60 su sistema di 20 elettroni non interagenti con insieme standardizzato. Il grafico (a) mette in relazione i valori predetti dal modello con quelli reali. Il grafico (b) mostra la distribuzione degli errori, definiti come $\Delta K_E = K_p - K$, dove K_p è il valore predetto e K il valore reale. L'insieme utilizzato è quello di test.

Modello	$\mathbf{T_A}$	**MSE**	$\mathbf{R^2}$
M5-60	3h 38min 2s	7.014×10^{-4}	0.9762

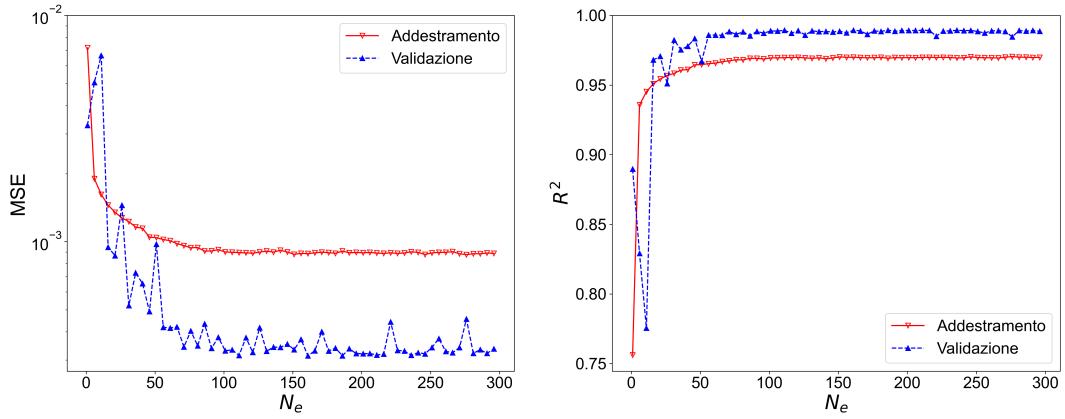
Tabella 4.5: Modello M5-60 su sistema di 20 elettroni non interagenti con insieme standardizzato. Tempo di addestramento (T_A), MSE e R^2 su insieme di test con $N_e = 300$.

Nonostante il problema di 20 elettroni non interagenti non introduca in principio maggiore difficoltà nel calcolo dell'energia rispetto al caso di un fermione, il modello ha prestazioni nettamente inferiori, a discapito di un tempo di addestramento molto più lungo, dovuto al maggior numero di istanze. È necessario quindi introdurre ulteriori modifiche per ridurre overfitting, oscillazione dei valori di MSE e R^2 calcolati su insieme di validazione e aumentare l'accuratezza. Esistono diverse strategie per cercare di ridurre queste problematiche. La nuova architettura prevede le seguenti modifiche:

- Standardizzazione del batch ad ogni livello della rete: dopo ogni livello della rete viene aggiunto un livello chiamato *batchnorm* [29], il quale esegue il processo di standardizzazione dell'output dello strato precedente.
- Riduzione della complessità della rete completamente connessa: il fenomeno dell'overfitting può essere causato da una rete troppo complessa. Il numero di livelli finali è ridotto da 6 a 2.
- Aggiunta del livello di dropout: il livello di dropout con probabilità $P = 0.2$ permette di azzerare l'output di alcuni neuroni del livello precedente durante l'addestramento, in modo tale da ridurre ulteriormente l'overfitting. Durante la validazione e test, il livello di dropout non è attivo.
- Aumento della dimensione del batch: l'oscillazione dei valori di MSE e R^2 sulla validazione può essere ridotta aumentando la dimensione del batch da 64 a 256.
- Aggiunta dello *scheduler*: lo *scheduler* permette di ridurre il tasso di apprendimento globale quando il MSE sui dati di validazione non diminuisce. L'algoritmo *Adam* introduce già un tasso di apprendimento variabile, ma modificando quello globale è possibile realizzare passi più fini.

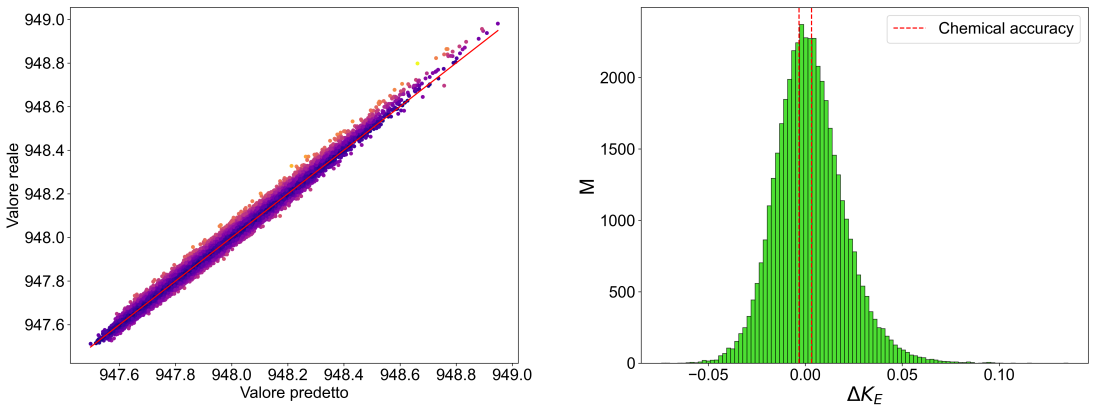
Le modifiche introdotte hanno portato ai risultati presenti nelle figure in seguito. I grafici in figura (4.22) mostrano un andamento diverso rispetto al caso precedente, in quanto il modello non presenta più overfitting. Il valore finale di MSE sui dati di validazione è ridotto del 56.5%, riducendo inoltre la sua oscillazione, in modo tale da avere un modello più affidabile. Il valore di R^2 è aumentato del 2%, dimostrando di avere accuratezza maggiore rispetto al caso precedente. La differenza tra i valori calcolati nell'insieme di addestramento e validazione è conseguenza del livello di dropout. Durante l'allenamento, il livello è attivo, riducendo conseguentemente l'accuratezza con l'obiettivo di ridurre l'overfitting. Durante la validazione invece, il livello non è attivo, permettendo il corretto calcolo di MSE e R^2. L'iperparametro che determina la probabilità di disattivare i neuroni del livello precedente è fissato a $P = 0.2$. Diversi valori hanno portato a risultati analoghi o peggiori. I dati riguardo le prestazioni del modello sono confermati anche dal grafico (4.23a), il quale mostra dispersione dei dati rispetto alla retta bisettrice minore, e dal grafico (4.23b), il quale mostra errori

minori al caso precedente. Nonostante ciò, l'errore è comunque maggiore alla *chemical accuracy*, in quanto solo il 15.3% rientra nell'intervallo definita da essa. Il grafico in figura (4.24) mostra l'andamento del tasso di apprendimento globale modificato dallo *scheduler*. Confrontato quest'ultimo con il grafico di MSE sui dati di validazione, si nota come al di sotto di 100 epoche la riduzione del tasso di apprendimento può aiutare la convergenza dell'algoritmo, mentre al di sopra di esso ridurlo ulteriormente non avrebbe portato a miglioramenti, in quanto il modello si trovava già in saturazione.



(a) (b)

Figura 4.22: Modello M5-60 modificato su sistema di 20 elettroni non interagenti. Il grafico (a) mostra l'andamento di MSE su dati di addestramento e validazione, mentre il grafico (b) mostra l'andamento di R^2 su i stessi dati



(a) (b)

Figura 4.23: Modello M5-60 modificato su sistema di 20 elettroni non interagenti. Il grafico (a) mette in relazione i valori predetti dal modello con quelli reali. Il grafico (b) mostra la distribuzione degli errori, definiti come $\Delta K_E = K_p - K$, dove K_p è il valore predetto e K il valore reale. L'insieme utilizzato è quello di test.

Modello	$\mathbf{T_A}$	**MSE**	$\mathbf{R^2}$
M5-60	3h 21min 50s	3.226×10^{-4}	0.989

Tabella 4.6: Modello M5-60 modificato su sistema di 20 elettroni non interagenti. Tempo di addestramento (T_A), MSE e R^2 su insieme di test con $N_e = 300$.

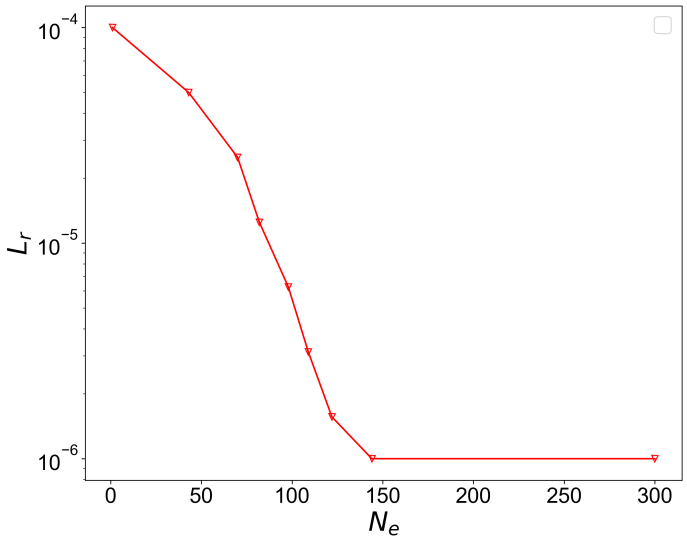


Figura 4.24: Modello M5-60 modificato su sistema di 20 elettroni non interagenti. Tasso di apprendimento globale (L_r) in funzione del numero di epoche

Non è stato possibile determinare un'architettura in grado di migliorare ulteriormente l'accuratezza sul sistema di 20 elettroni non interagenti. Per quanto il valore di R^2 raggiunto sia molto vicino ad 1, il valore di MSE è ancora troppo elevato, non permettendo di rientrare nella *chemical accuracy*. In seguito, è mostrato un metodo alternativo per ricavare la relazione tra densità dello stato fondamentale e energia cinetica associata, con l'obiettivo di abbattere la soglia di $MSE = 3 \times 10^{-4}$.

4.2.3 Sistema di 10 elettroni non interagenti

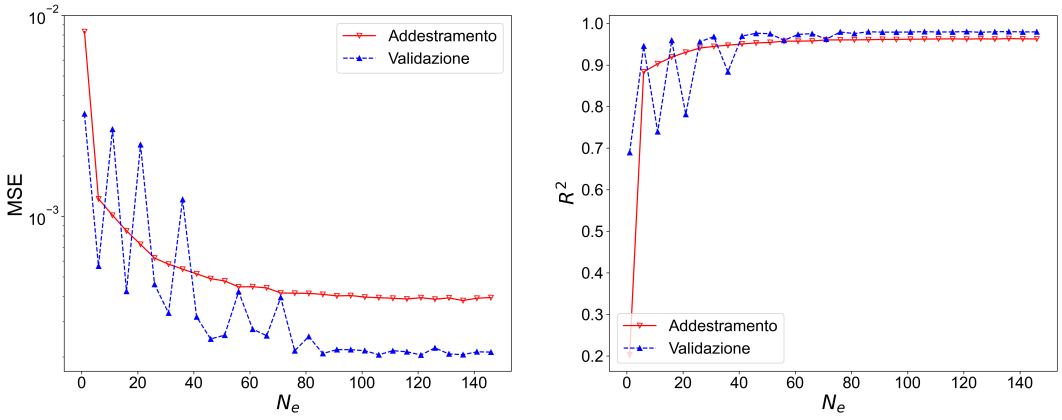
Il problema riscontrato della bassa accuratezza dei modelli di apprendimento automatico su sistemi a più elettroni ha portato allo studio di un nuovo sistema con un numero minore di elettroni e energie separate per stati. Mantenendo invariata l'architettura e i parametri di addestramento, l'analisi si è incentrata sulle diverse dimensioni di input e output della rete. In particolare, sono trattate quattro tipologie:

- Input singolo canale e output scalare: come nei sistemi precedenti, in questo caso l'input è la densità elettronica dello stato fondamentale, mentre l'output della rete è l'energia cinetica totale del sistema.

- Input singolo canale e output vettoriale di dimensione 5: l'input è la densità elettronica, mentre l'output sono le singole energie cinetiche dei livelli energetici.

- Input doppio canale e output scalare: l'input ora è dato da un tensore contente la densità elettronica e il potenziale associato, mentre l'output è l'energia cinetica totale del sistema.

Il primo caso trattato è quello di input singolo canale e output scalare. La figura (4.25) mostra un andamento di MSE e R^2 poco migliore rispetto al caso di 20 elettroni, indicando che l'accuratezza, nel caso di sistemi con più elettroni, non dipende in modo marcato dal numero effettivo di essi. Ciò è confermato anche dai grafici in figura (4.26), dove si nota, soprattutto nel grafico (4.26a), una riduzione minima dell'errore. La percentuale di dati al di sotto della *chemical accuracy* è del 18.9%, valore simile al caso dei 20 elettroni. La tabella (4.7) mostra un tempo di addestramento ridotto rispetto al caso di 20 elettroni dovuto al minore numero di istanze, a fronte di una piccola diminuzione di MSE e aumento di R^2. La differenza di energia cinetica tra il primo e secondo livello energetico e l'andamento quasi costanti dei livelli con n maggiore di 2, mostrati nella sezione (4.1.3) relativa alla descrizione del sistema, può essere una possibile causa del problema, poiché la rete non riesce ad apprendere le piccole variazioni date solo dal primo livello energetico. Il metodo di input con singolo canale e output vettoriale è introdotto per cercare di ridurre questa problematica. L'idea è separare i singoli contributi dell'energia cinetica dei vari livelli energetici in output, così da rendere esplicito l'effetto della densità elettronica sui vari livelli. La distribuzione dell'energia cinetica per livello è resa standard utilizzando il processo descritto nella relazione (4.6).

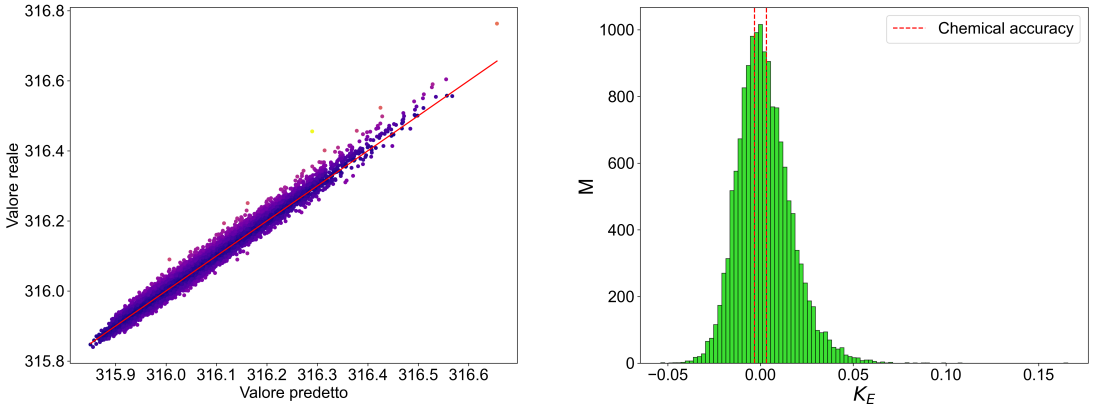


(a) (b)

Figura 4.25: Modello M5-60 modificato su sistema di 10 elettroni non interagenti con insieme standardizzato, input singolo canale e output scalare. Il grafico (a) mostra l'andamento di MSE su dati di addestramento e validazione, mentre il grafico (b) mostra l'andamento di R^2 su i stessi dati

Modello	$\mathbf{T_A}$	**MSE**	$\mathbf{R^2}$
M5-60 mod.	1h 9min 16s	2.205×10^{-4}	0.9784

Tabella 4.7: Modello M5-60 modificato su sistema di 10 elettroni non interagenti con insieme standardizzato, input singolo canale e output scalare. Tempo di addestramento (T_A), MSE e R^2 su insieme di test con $N_e = 300$.



(a) (b)

Figura 4.26: Modello M5-60 modificato su sistema di 10 elettroni non interagenti con insieme standardizzato, input singolo canale e output scalare. Il grafico (a) mette in relazione i valori predetti dal modello con quelli reali. Il grafico (b) mostra la distribuzione degli errori, definiti come $\Delta K_E = K_p - K$, dove K_p è il valore predetto e K il valore reale. L'insieme utilizzato è quello di test.

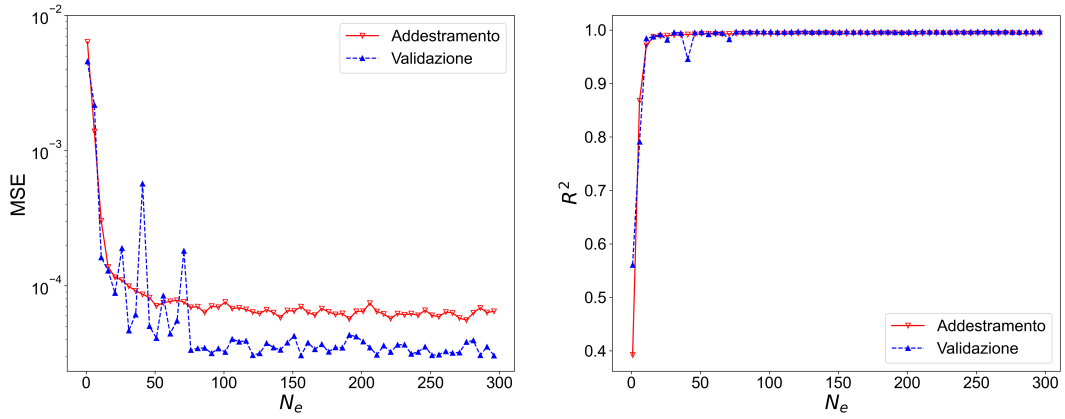
La seguente tabella mostra il risultato finale sull'insieme di test dell'applicazione del metodo di input con singolo canale e output vettoriale al modello M5-60 modificato. Confrontando con il metodo precedente, la separazione dei contributi dell'energia cinetica non ha portato a miglioramenti significativi di accuratezza. Questo suggerisce che il modello non sfrutta la divisione dell'energia nei contributi dei singoli livelli, e che la rappresentazione a singolo valore scalare è sufficiente per questo sistema.

Modello	$\mathbf{T_A}$	**MSE**	$\mathbf{R^2}$
M5-60 mod.	1h 12min 34s	2.328×10^{-4}	0.9771

Tabella 4.8: Modello M5-60 modificato su sistema di 10 elettroni non interagenti con insieme standardizzato, input singolo canale e output vettoriale. Tempo di addestramento (T_A), MSE e R^2 su insieme di test con $N_e = 300$.

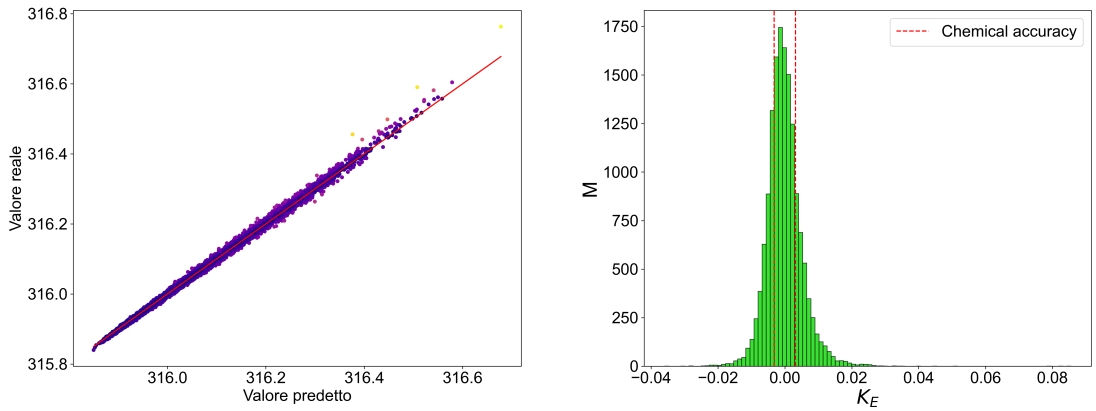
Un ulteriore opzione è aumentare l'informazione in input alla rete, utilizzando la densità elettronica dello stato fondamentale e il potenziale associato in input alla rete. Come per la densità, anche la distribuzione dei valori del potenziale è resa standard. I seguenti grafici mostrano i risultati riguardo l'accuratezza raggiunta dal modello. L'andamento di MSE e R^2, illustrati in figura (4.27), convergono a valori nettamente migliori rispetto ai casi precedenti, raggiungendo MSE $= 3.057 \times 10^{-5}$, ovvero un ordine di grandezza in meno, e $R^2 = 0.9970$ nei dati di validazione. Inoltre, presenta una minore oscillazione dei valori nelle prime epoche. Il grafico in figura (4.28a) evidenzia una minore dispersione dei dati rispetto all'asse bisettrice, indicando valori predetti molto più accurati. Ciò è visibile anche in figura (4.28b), dove l'errore è centrato in 0 e con code molto più ristrette rispetto al caso precedente. Il 53.3% dei dati, rientra nell'intervallo definito dalla *chemical accuracy*, valore molto maggiore rispetto al caso in cui l'input è dato dalla sola densità elettronica. La tabella (4.9) conferma questi dati anche nell'insieme di test, mostrando MSE ridotto di un fattore 10 e R^2

maggiore a fronte dello stesso tempo di addestramento rispetto ai dati nella tabella (4.7). Nonostante ciò, il modello ha accuratezza ancora molto inferiore rispetto al caso di singolo elettrone, dimostrando che per questo determinato sistema con più elettroni caratterizzato dal potenziale definito in (4.1), la rete non è in grado di raggiungere accuratezza elevata utilizzando solo la densità elettronica dello stato fondamentale, ma necessità di maggiore informazione.



(a) (b)

Figura 4.27: Modello M5-60 modificato su sistema di 10 elettroni non interagenti con insieme standardizzato, input doppio canale e output scalare. Il grafico (a) mostra l'andamento di MSE su dati di addestramento e validazione, mentre il grafico (b) mostra l'andamento di R^2 su i stessi dati



(a) (b)

Figura 4.28: Modello M5-60 modificato su sistema di 10 elettroni non interagenti con insieme standardizzato, input doppio canale e output scalare. Il grafico (a) mette in relazione i valori predetti dal modello con quelli reali. Il grafico (b) mostra la distribuzione degli errori, definiti come $\Delta K_E = K_p - K$, dove K_p è il valore predetto e K il valore reale. L'insieme utilizzato è quello di test.

Modello	$\mathbf{T_A}$	**MSE**	$\mathbf{R^2}$
M5-60 mod.	1h 12min 47s	2.912×10^{-5}	0.9971

Tabella 4.9: Modello M5-60 modificato su sistema di 10 elettroni non interagenti con insieme standardizzato, input doppio canale e output scalare. Tempo di addestramento (T_A), MSE e R^2 su insieme di test con $N_e = 300$.

4.3 Processo di minimizzazione

Dimostrata la possibilità di apprendere il funzionale dell'energia cinetica utilizzando un modello di apprendimento automatico abbastanza profondo, l'obiettivo è ricavare la densità dello stato fondamentale dato un generico potenziale non appartenente all'insieme di addestramento. Il secondo teorema di Hohenberg-Khon afferma che il funzionale dell'energia totale assume il minimo quando è valutato sulla densità dello stato fondamentale. L'idea è quindi applicare un processo di minimizzazione vincolato, in quanto la densità integrata nello spazio deve dare come risultato il numero di elettroni nel sistema, per il funzionale dell'energia cinetica per determinare la densità ricercata. Analogamente a quanto fatto nella sezione relativa al metodo di Khon-Sham, la minimizzazione del funzionale avviene applicando il metodo dei moltiplicatori di Lagrange:

$$\delta \left[E[n(\mathbf{r})] - \mu \left(\int n(\mathbf{r}) d\mathbf{r} - N \right) \right] = 0, \tag{4.7}$$

che equivale, esplicitando $E[n(\mathbf{r})] = T[n(\mathbf{r})] + \int V(\mathbf{r}) n(\mathbf{r}) d\mathbf{r}$, alla equazione di Eulero:

$$\frac{\delta T[n(\mathbf{r})]}{\delta n(\mathbf{r})} + V(\mathbf{r}) - \mu = 0. \tag{4.8}$$

L'equazione di Eulero è risolta numericamente utilizzando l'algoritmo di discesa del gradiente:

$$n_{t+1}(\mathbf{r}) = n_t(\mathbf{r}) - \eta \left(\frac{\delta T[n_t(\mathbf{r})]}{\delta n(\mathbf{r})} + V(\mathbf{r}) - \mu_t \right), \tag{4.9}$$

dove la densità iniziale $t = 0$ è scelta in modo coerente con il sistema, η è il tasso di apprendimento ed il coefficiente μ_t assicura il vincolo sulla densità. Come nel caso delle reti neurali, la convergenza dell'algoritmo al minimo assoluto non è assicurato, in quanto potrebbe bloccarsi in un minimo locale. È possibile però ridurre il problema applicando il processo molte volte utilizzando profili di densità iniziali diversi. Un secondo problema riportato in diversi articoli, tra cui [9], riguarda il calcolo della derivata del funzionale appreso tramite utilizzo di CNNs convenzionali. Generalmente, questa risulta rumorosa e inaccurata, dando luogo a profili di densità non corrispondenti allo stato fondamentale di alcun sistema. Il funzionale valutato in questo profilo darebbe quindi predizioni errate. Nell'articolo citato, è introdotta un'architettura di CNN, chiamata $\overline{\text{CNN}}$, dove ogni blocco convoluzionale implementa livelli dove ogni neurone calcola la media delle attivazioni dei neuroni corrispondenti ai canali del livello precedente. La rete è testata su un sistema di singola particella unidimensionale con potenziale casuale progettato per rappresentare l'effetto di pattern di speckle ottico su atomi ultrafreddi. L'errore relativo tra densità reale $n_{\text{gs}}(x)$ e quella determinata applicando l'algoritmo di discesa

del gradiente $n_{\min}(x)$ è definito nel seguente modo:

$$|\Delta n| = \sqrt{\int (n_{gs}(x) - n_{\min}(x))^2 \mathrm{d}x} \tag{4.10}$$

L'analisi mostra valori di R^2 di una CNN tradizionale leggermente superiori rispetto a $\overline{\text{CNN}}$, determinando quindi una minore accuratezza della mappa tra densità e energia cinetica di quest'ultima. È mostrato però che l'errore relativo della CNN tende a diminuire inizialmente, raggiungendo circa il 20%, per poi aumentare dopo un certo numero di step, mentre per $\overline{\text{CNN}}$ l'errore diminuisce in modo regolare, raggiungendo la saturazione a 0.05%.

4.4 Applicazione dell'autoencoder variazionale

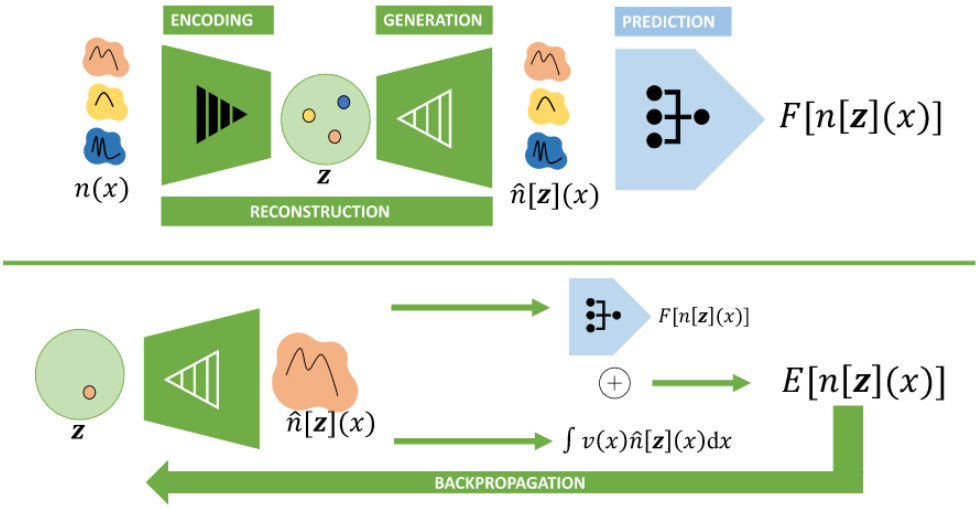


Figura 4.29: Rappresentazione schematica del processo di minimizzazione utilizzato sfruttando VAE e CNN. Immagine tratta da [9]

.

Ulteriori studi sono stati realizzati per mitigare il problema del calcolo del gradiente poco accurato del funzionale durante il processo di minimizzazione. In questa sezione è riportato un metodo che utilizza un VAE, allenato per riprodurre accuratamente i profili di densità appartenenti all'insieme di addestramento, per evitare di ottenere profili di densità durante il processo di minimizzazione non fisici. In figura (4.29) è presentato lo schema del processo. La parte superiore della figura mostra il meccanismo di codifica della densità $n(x)$ nella rappresentazione compressa $\mathbf{z}$ appartenente allo spazio latente e la ricostruzione del medesimo profilo di densità $\hat{n}[\mathbf{z}](x)$ utilizzando $\mathbf{z}$, come descritto nella sezione (3.4). L'output del VAE è collegato ad una CNN allenata per apprendere la relazione tra densità e energia cinetica. La parte inferiore della figura mostra il processo di minimizzazione utilizzando lo spazio latente. L'idea è definire il funzionale dell'energia dipendente dalla rappresentazione compressa delle densità, ovvero:

$$E[\mathbf{z}] = F[\hat{n}[\mathbf{z}](x)] + \int v(x)\hat{n}[\mathbf{z}](x)dx, \tag{4.11}$$

dove $F[\hat{n}[\mathbf{z}](x)]$ è il valore della CNN valutato nel profilo di densità generato dal VAE utilizzando $\mathbf{z}$ e $v(x)$ è il potenziale esterno. Il funzionale $E[\mathbf{z}]$ presenta un minimo in $\mathbf{z}_{\text{gs}}$ quando:

$$\frac{\delta E[\mathbf{z}_{\text{gs}}]}{\delta \mathbf{z}} = \int \left(\frac{\delta F[n_{\text{gs}}(x)]}{\delta n_{\text{gs}}(x)} + v(x) \right) \frac{\delta \hat{n}[\mathbf{z}](x)}{\delta \mathbf{z}} = 0. \tag{4.12}$$

Per determinare la rappresentazione compressa della densità dello stato fondamentale $\mathbf{z}_{\text{gs}}$, è possibile utilizzare l'algoritmo di discesa del gradiente come:

$$\mathbf{z}_{t+1} = \mathbf{z}_t - \eta \frac{\delta E[\mathbf{z}_t]}{\delta \mathbf{z}_t}, \tag{4.13}$$

dove η è il tasso di apprendimento. A differenza dell'equazione (4.9), in questo caso il coefficiente μ_t non è necessario, poiché la condizione di normalizzazione è imposta nella generazione data dal VAE. Determinato $\mathbf{z}_{\text{gs}}$, è possibile ottenere la densità dello stato fondamentale utilizzando il decoder del VAE, ovvero $n_{\text{gs}}(x) = \hat{n}[\mathbf{z}_{\text{gs}}](x)$ e l'energia associata, come $e_{\text{gs}} = E[\mathbf{z}_{\text{gs}}]$. Il VAE, essendo allenato per generare profili di densità realistici dato un generico vettore appartenente allo spazio latente, permette di evitare che la densità calcolata sia al di fuori dello spazio di definizione del funzionale dell'energia durante il processo di minimizzazione, aumentando l'accuratezza dei risultati ottenuti.

5. Conclusioni

Il presente lavoro di tesi si è focalizzato sull'applicazione di tecniche di apprendimento automatico all'interno della teoria del funzionale della densità, con l'obiettivo di ricavare l'energia dello stato fondamentale di un sistema con numero variabile di elettroni in presenza di un potenziale dato dalla somma di gaussiane con parametri casuali. La motivazione principale risiede nella difficoltà computazionale della risoluzione diretta dell'equazione di Schrödinger per sistemi a molti corpi. In questo contesto, l'utilizzo di reti neurali promette di raggiungere un'accuratezza elevata con un costo computazionale relativamente basso. In particolare, si sono analizzate inizialmente le prestazioni di diverse architetture di CNN addestrate per mappare la densità all'energia cinetica su un insieme di dati ricavati dalla risoluzione del sistema di singolo elettrone. La prima analisi ha riguardato l'effetto del numero di blocchi convoluzionali e di pooling sull'accuratezza e sul tempo di addestramento. I risultati mostrano che all'aumentare dei blocchi entrambi aumentano fino al limite di 6 blocchi, oltre il quale la rete produce un output costante corrispondente al valor medio dei dati. La seconda analisi ha riguardato l'effetto della dimensione di output dell'ultimo blocco, ovvero quello collegato alla rete completamente connessa: l'utilizzo di un singolo valore per canale ha permesso di raggiungere l'accuratezza massima riducendo al contempo il tempo di addestramento. Utilizzando quindi una CNN composta da 5 blocchi e una dimensione di input per la rete completamente connessa pari a 60, si ottiene un'accuratezza tale da avere errore tra dati reali e predetti minore della *chemical accuracy*, dimostrando che, per questo sistema, una rete neurale è in grado di approssimare efficacemente il funzionale dell'energia cinetica. Il secondo insieme di dati considerato è dato dalla risoluzione del sistema di 20 elettroni. Applicando la stessa architettura del caso a singolo elettrone a dati con distribuzione non standard, la rete non è riuscita a convergere, producendo risultati peggiori di un semplice modello costante pari al valor medio. È stata quindi introdotta la standardizzazione dei dati, ottenendo però accuratezza bassa e overfitting. Sono state quindi realizzate delle modifiche all'architettura di rete. In particolare, è stato ridotto il numero di livelli della rete completamente connessa, aggiunto livelli di dropout e batch normalization, insieme allo scheduler, con obiettivo ridurre l'overfitting. Queste modifiche hanno prodotto risultati migliori, ma l'errore è rimasto al di sopra della *chemical accuracy*, con solo il 15.3% dei campioni all'interno di tale intervallo. Per approfondire questo aspetto, si è costruito un nuovo insieme di dati dalla risoluzione del sistema di 10 elettroni, in cui l'energia è scomposta nei contributi dei singoli livelli energetici. L'analisi ha mostrato come il primo livello abbia energia significativamente inferiore rispetto agli altri. Utilizzando la stessa architettura CNN, si sono studiate diverse configurazioni di input e output. Con densità come input ed energia cinetica totale come output, i risultati sono analoghi al caso di 20 elettroni. Passando a un output vettoriale 5-dimensionale corrispondente ai contributi dei singoli livelli, non si sono osservati miglioramenti significativi. Aggiungendo invece il potenziale al vettore

di input, l'accuratezza è migliorata notevolmente: il 53.3% dei campioni rientra nella *chemical accuracy*, dimostrando che la sola densità non contiene informazioni sufficienti per ottenere predizioni su questo sistema.

I risultati ottenuti, soprattutto per il caso a singolo elettrone, dimostrano la possibilità di approssimare il funzionale dell'energia cinetica tramite una CNN. Tuttavia, il caso a più elettroni ha evidenziato diverse problematiche che meritano ulteriori studi. Una prima direzione consiste nell'addestrare il modello su potenziali di natura diversa, al fine di determinare se le difficoltà osservate siano specifiche al sistema considerato o intrinseche ai sistemi multi-particella in generale. Inoltre, andrebbe approfondito il ruolo del potenziale come input alla rete: i risultati ottenuti suggeriscono che esso possa compensare la mancanza di informazione della sola densità, aprendo la possibilità di eliminare quest'ultima come variabile di input. Infine, andrebbero studiati il ruolo, l'effettiva applicabilità e possibili miglioramenti del processo di minimizzazione con i funzionali appresi per ricavare la densità dello stato fondamentale e, conseguentemente, l'energia associata.

Ringraziamenti

Desidero dedicare questa parte della mia tesi a tutte le persone che, con la loro presenza e il loro supporto, hanno reso possibile la conclusione di questo percorso.

Vorrei ringraziare in primo luogo il relatore, il Prof. Sebastiano Pilati, per avermi seguito con attenzione e costante disponibilità durante l'intera stesura di questa tesi.

Un ringraziamento speciale va alla mia famiglia: i miei genitori, mia sorella e mio fratello, gli zii e nonni, che con il loro sostegno mi hanno permesso di intraprendere questo percorso e di portarlo a termine con serenità.

Infine, un grazie di cuore a tutti i miei amici, coloro con cui ho condiviso questi ultimi anni e che hanno reso il percorso universitario più leggero e piacevole.

Bibliografia

[1] Richard M. Martin. *Electronic Structure: Basic Theory and Practical Methods*. 2ª ed. Cambridge University Press, ago. 2020. ISBN: 978-1-108-55558-6 978-1-108-42990-0. DOI: 10.1017/9781108555586.

[2] Ryosuke Akashi, Mihira Sogal e Kieron Burke. *Can Machines Learn Density Functionals? Past, Present, and Future of ML in DFT*. Mar. 2025. DOI: 10.48550/arXiv.2503.01709. arXiv: 2503.01709 [physics]. URL: http://arxiv.org/abs/2503.01709.

[3] John C. Snyder et al. ≪Finding Density Functionals with Machine Learning≫. In: *Physical Review Letters* 108.25 (giu. 2012), p. 253002. ISSN: 0031-9007, 1079-7114. DOI: 10.1103/PhysRevLett.108.253002. arXiv: 1112.5441 [physics]. URL: http://arxiv.org/abs/1112.5441.

[4] Li Li et al. *Understanding Machine-learned Density Functionals*. Mag. 2014. DOI: 10.48550/arXiv.1404.1333. arXiv: 1404.1333 [physics]. URL: http://arxiv.org/abs/1404.1333.

[5] Emanuele Costa et al. ≪Deep Learning Density Functionals for Gradient Descent Optimization≫. In: *Physical Review E* 106.4 (ott. 2022), p. 045309. ISSN: 2470-0045, 2470-0053. DOI: 10.1103/PhysRevE.106.045309. arXiv: 2205.08367 [physics]. URL: http://arxiv.org/abs/2205.08367.

[6] John C. Snyder et al. ≪Nonlinear Gradient Denoising: Finding Accurate Extrema from Inaccurate Functional Derivatives≫. In: *International Journal of Quantum Chemistry* 115.16 (2015), pp. 1102–1114. ISSN: 1097-461X. DOI: 10.1002/qua.24937. URL: https://onlinelibrary.wiley.com/doi/abs/10.1002/qua.24937.

[7] Felix Brockherde et al. ≪Bypassing the Kohn-Sham Equations with Machine Learning≫. In: *Nature Communications* 8.1 (ott. 2017), p. 872. ISSN: 2041-1723. DOI: 10.1038/s41467-017-00839-3. URL: https://www.nature.com/articles/s41467-017-00839-3.

[8] Kevin Ryczko, David Strubbe e Isaac Tamblyn. ≪Deep Learning and Density Functional Theory≫. In: *Physical Review A* 100.2 (ago. 2019), p. 022512. ISSN: 2469-9926, 2469-9934. DOI: 10.1103/PhysRevA.100.022512. arXiv: 1811.08928 [cond-mat]. URL: http://arxiv.org/abs/1811.08928.

[9] Emanuele Costa, Giuseppe Scriva e Sebastiano Pilati. ≪Solving Deep-Learning Density Functional Theory via Variational Autoencoders≫. In: *Machine Learning: Science and Technology* 5.3 (set. 2024), p. 035015. ISSN: 2632-2153. DOI: 10.1088/2632-2153/ad611f. URL: https://iopscience.iop.org/article/10.1088/2632-2153/ad611f.

[10] P. Hohenberg e W. Kohn. «Inhomogeneous Electron Gas». In: *Physical Review* 136.3B (nov. 1964), B864–B871. ISSN: 0031-899X. DOI: 10.1103/PhysRev.136.B864.

[11] W. Kohn e L. J. Sham. «Self-Consistent Equations Including Exchange and Correlation Effects». In: *Physical Review* 140.4A (nov. 1965), A1133–A1138. ISSN: 0031-899X. DOI: 10.1103/PhysRev.140.A1133.

[12] William C. Witt et al. «Orbital-Free Density Functional Theory for Materials Research». In: *Journal of Materials Research* 33.7 (apr. 2018), pp. 777–795. ISSN: 0884-2914, 2044-5326. DOI: 10.1557/jmr.2017.462.

[13] Mel Levy. «Universal Variational Functionals of Electron Densities, First-Order Density Matrices, and Natural Spin-Orbitals and Solution of the v -Representability Problem». In: *Proceedings of the National Academy of Sciences* 76.12 (dic. 1979), pp. 6062–6065. ISSN: 0027-8424, 1091-6490. DOI: 10.1073/pnas.76.12.6062. URL: https://pnas.org/doi/full/10.1073/pnas.76.12.6062.

[14] David García-Aldea e J. Alvarellos. «The construction of kinetic energy functionals and the linear response function». In: *Theoretical and Computational Developments in Modern Density Functional Theory* (ott. 2012), pp. 255–280.

[15] Pilati Sebastiano. *Lezioni di machine learning e sue applicazioni*. 2024.

[16] *Cos'è il machine learning? | IBM*. Ago. 2025. URL: https://www.ibm.com/it-it/think/topics/machine-learning.

[17] *Cos'è l'apprendimento non supervisionato? | IBM*. Set. 2021. URL: https://www.ibm.com/it-it/think/topics/unsupervised-learning.

[18] *Cosa è l'apprendimento supervisionato? | IBM*. Set. 2025. URL: https://www.ibm.com/it-it/think/topics/supervised-learning.

[19] *Cosa Sono l'overfitting e l'underfitting? | IBM*. URL: https://www.ibm.com/it-it/think/topics/overfitting-vs-underfitting.

[20] *Overfitting e underfitting*. URL: https://it.mathworks.com/discovery/overfitting.html.

[21] *Cos'è una rete neurale? | IBM*. Ott. 2021. URL: https://www.ibm.com/it-it/think/topics/neural-networks.

[22] Kurt Hornik. «Approximation Capabilities of Multilayer Feedforward Networks». In: *Neural Networks* 4.2 (gen. 1991), pp. 251–257. ISSN: 0893-6080. DOI: 10.1016/0893-6080(91)90009-T. URL: https://www.sciencedirect.com/science/article/pii/089360809190009T.

[23] Zhou Lu et al. *The Expressive Power of Neural Networks: A View from the Width*. Nov. 2017. DOI: 10.48550/arXiv.1709.02540. arXiv: 1709.02540 [cs]. URL: http://arxiv.org/abs/1709.02540.

[24] *Convolutional_networks*. URL: https://courses.cs.washington.edu/courses/cse446/22wi/sections/08/convolutional_networks.html.

[25] *Che cos'è una rete neurale convoluzionale?* URL: https://it.mathworks.com/discovery/convolutional-neural-network.html.

[26] «Variational Autoencoder». In: *Wikipedia* (feb. 2026). URL: https://en.wikipedia.org/w/index.php?title=Variational_autoencoder&oldid=1340358343.

[27] Roman Remme et al. ≪Stable and Accurate Orbital-Free Density Functional Theory Powered by Machine Learning≫. In: *Journal of the American Chemical Society* 147.32 (ago. 2025), pp. 28851–28859. ISSN: 0002-7863, 1520-5126. DOI: 10.1021/jacs.5c06219. URL: https://pubs.acs.org/doi/10.1021/jacs.5c06219.

[28] Diederik P. Kingma e Jimmy Ba. *Adam: A Method for Stochastic Optimization*. Gen. 2017. DOI: 10.48550/arXiv.1412.6980. arXiv: 1412.6980 [cs]. URL: http://arxiv.org/abs/1412.6980.

[29] Sergey Ioffe e Christian Szegedy. *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*. Mar. 2015. DOI: 10.48550/arXiv.1502.03167. arXiv: 1502.03167 [cs]. URL: http://arxiv.org/abs/1502.03167.

[30] Forlucci Jonathan. *Deep learning applied to density functional theory*. 2024.